

PREDIKSI KUALITAS LAPORAN KEUANGAN KEMENTERIAN NEGARA/LEMBAGA MENGGUNAKAN *MACHINE LEARNING*

Teguh Puspandoyo, Widha Adinata, Laode Atthar Alfikry, Tyas Ayu Prasanti, Silvi Yuniar
Direktorat Akuntansi dan Pelaporan Keuangan

Abstract

Quality financial reports are one of the tools in realizing government accountability. However, not all State Ministries/Agencies yet have received the best opinion. Therefore, this study aims to analyze the influencing factors and also make predictions and classification of quality of State Ministries/Agencies of financial reports using machine learning techniques. The sample used in this study was 259 State Ministries/Agencies from 2018-2020. The results show that cash fraud, findings, follow-up to BPK's recommendations, the money supply/additional money supply, and realization have a strong influence in determining quality of financial reports. In addition, with the Support Vector Machine model, better classification predictions are obtained for quality of State Ministries/Agencies of financial reports.

Abstrak

Laporan keuangan yang berkualitas menjadi salah satu *tools* dalam mewujudkan akuntabilitas pemerintah. Namun, belum seluruh Kementerian Negara/Lembaga mendapatkan opini terbaik. Oleh karenanya, riset ini bertujuan untuk menganalisis faktor yang berpengaruh sekaligus membuat prediksi klasifikasi atas kualitas laporan keuangan Kementerian Negara/Lembaga melalui teknik *machine learning*. Sampel yang digunakan dalam penelitian ini sebanyak 259 Kementerian Negara/Lembaga dari tahun 2018-2020. Hasil penelitian menunjukkan bahwa *fraud* kas, temuan, tindak lanjut atas rekomendasi BPK, UP/TUP, dan realisasi mempunyai pengaruh yang kuat dalam menentukan kualitas laporan keuangan. Selain itu, dengan model *Support Vector Machine* didapatkan prediksi klasifikasi yang lebih baik atas Kualitas laporan keuangan Kementerian Negara/Lembaga.

Keywords: Audit, Kualitas Laporan Keuangan, *Machine Learning*, *Support Vector Machine*

JEL Classification: M41, M42

PENDAHULUAN

Akuntabilitas merupakan sebuah amanat Undang-Undang yang harus diimplementasikan. Dalam Paket Undang-Undang Keuangan Negara, telah diatur bagaimana pola pengelolaan keuangan negara hingga pelaporan dan pemeriksaannya. Laporan keuangan yang berkualitas menjadi salah satu *tools* dalam mewujudkan akuntabilitas pemerintah. Selain itu, laporan keuangan juga digunakan untuk mengetahui nilai sumber daya ekonomi yang dimanfaatkan dalam pelaksanaan kegiatan operasional pemerintah, menilai kondisi keuangan, dan mampu membantu menentukan ketaatan terhadap peraturan perundang-undangan (Windarsih, 2015).


Laporan keuangan harus berkualitas untuk mendukung pengambilan kebijakan berbagai pihak. Informasi dalam laporan keuangan harus bermanfaat bagi para pemakai (Simanungkalit, 2015). Salah satu indikator kualitas pengelolaan dan pertanggungjawaban keuangan pemerintah adalah opini BPK atas laporan keuangan. Opini dari BPK terbagi atas beberapa tingkatan, yakni Tidak Wajar, Tidak Memberikan Pendapat (TMP), Wajar Dengan Pengecualian (WDP), dan yang tertinggi Wajar Tanpa Pengecualian (WTP).

Standar Akuntansi Pemerintahan menjelaskan bahwa karakteristik kualitatif laporan keuangan yakni ukuran normatif yang harus diwujudkan dalam informasi akuntansi supaya mampu memenuhi tujuannya. Dalam Kerangka Konseptual Akuntansi Pemerintahan unsur pembentuk kualitas informasi yakni relevan, andal, dapat

diperbandingkan, dan dapat dipahami. Dalam rangka mewujudkan Kualitas informasi tersebut, Pemerintah Pusat membuat dan mengembangkan Sistem Akuntansi Pemerintah Pusat (SAPP) yang akan menghasilkan Laporan Keuangan Pemerintah Pusat (LKPP) sebagaimana diatur dalam Peraturan Menteri Keuangan Nomor 215/PMK.05/2016. SAPP tersebut terdiri dari dua subsistem, yakni Sistem Akuntansi Bendahara Umum Negara (SA-BUN) dan Sistem Akuntansi Instansi (SAI). SA-BUN akan menghasilkan Laporan Keuangan BUN (LK-BUN) dan SAI akan menghasilkan Laporan Keuangan Kementerian Negara/Lembaga (LKKL).

Kualitas LKPP dipengaruhi oleh Kualitas LK-BUN dan LKKL karena merupakan konsolidasi dari kedua laporan tersebut. Semenjak tahun 2016 hingga tahun 2020, LKPP dan LK-BUN selalu mendapatkan opini WTP dari BPK. Lain halnya dengan LKKL, semenjak tahun 2016 sampai dengan 2020 belum pernah seluruh LKKL mendapatkan opini WTP sebagaimana disajikan dalam grafik berikut:

Grafik 1. Perbandingan Persentase Perolehan Opini WTP LKPP dan LKKL tahun 2016 s.d. 2020



Sumber: LKPP dan LKKL (diolah)

Selain itu, Presiden Republik Indonesia telah menyatakan bahwa opini WTP bukanlah sebuah prestasi melainkan kewajiban dalam mengelola anggaran negara (nasional.okezone, 2017). Hal ini berarti bahwa masih terdapat Kementerian Negara/Lembaga yang belum memenuhi kewajiban pengelolaan keuangan dengan baik.

Penelitian tentang faktor apa saja yang berpengaruh terhadap kualitas laporan keuangan yang dicerminkan dengan opini audit telah dilakukan oleh peneliti terdahulu. Sutaryo, et al. (2020) menemukan bahwa kompleksitas, ukuran, dan tipe Pemerintah Daerah, pengawasan keuangan, dan pengesahan atas APBD serta penyampaian Laporan Keuangan Pemda (LKPD) berpengaruh signifikan terhadap opini audit Pemda. Kewo, C.L. dan Afiah N.N. (2017) menemukan bahwa sistem pengendalian internal dan audit internal secara parsial dan simultan berpengaruh positif dan signifikan terhadap kualitas laporan keuangan. Berbeda, Nurdiono et al (2016) menemukan bahwa efektivitas pengendalian internal, kompetensi SDM, dan tindak lanjut atas rekomendasi BPK tidak berpengaruh signifikan terhadap opini audit LKPD. Beberapa penelitian tersebut mengambil fokus penelitian di Pemerintah Daerah.

Penelitian mengenai faktor yang berpengaruh terhadap kualitas laporan keuangan di level pemerintah pusat khususnya Kementerian Negara/Lembaga sebagai sebuah konsolidasian seluruh Satuan Kerja (Satker) dibawahnya masih sangat jarang. Simanungkalit A. (2015) yang mengambil objek Satker di wilayah Banda Aceh dan menggunakan data primer menemukan bahwa penerapan

SAP, kualitas SDM, sistem pengendalian internal, komitmen organisasi, dan pemanfaatan teknologi informasi berpengaruh positif signifikan terhadap kualitas laporan keuangan. Roni et al. (2019) menemukan bahwa penerapan SAP dan teknologi informasi berpengaruh positif signifikan sedangkan kompetensi SDM dan sistem rekonsiliasi tidak berpengaruh terhadap Kualitas laporan keuangan. Hanya Sari A.P. (2016) yang mencoba meneliti menggunakan objek Kementerian Negara/Lembaga dan menggunakan data sekunder, dimana hasilnya ditemukan bahwa temuan audit, tindak lanjut hasil pemeriksaan, dan kapasitas operator pengelolaan keuangan berpengaruh positif terhadap opini audit melalui tingkat pengungkapan laporan keuangan.

Riset ini akan mengembangkan hasil dari penelitian sebelumnya dengan menggunakan sampel dari tahun yang lebih baru dan menggunakan lebih banyak variabel untuk mendapatkan hasil yang komprehensif. Beberapa variabel yang ditambahkan yakni terkait adanya kasus yang terindikasi fraud, indikator kinerja pelaksanaan anggaran, umur Kementerian Negara/Lembaga, dan karakteristik pimpinan kementerian negara/Lembaga. Penelitian ini mengambil objek pada Kementerian Negara/Lembaga karena belum seluruh Kementerian Negara/Lembaga mendapatkan opini WTP, yang artinya masih terdapat Kementerian Negara/Lembaga yang belum *comply* atas amanat Presiden diatas. Selain itu, sesuai grafik 1 diatas, masih terdapat gap antara opini LKPP dengan LKKL, padahal LKPP merupakan konsolidasian dari LKKL dan LK BUN. Hal ini berarti

kualitas LKKL berpengaruh terhadap kualitas LKPP.

Sejalan, riset ini juga mencoba untuk melakukan analisis menggunakan teknik *machine learning* untuk mendapatkan hasil yang komprehensif. Selain itu, riset ini juga akan menguji hipotesis faktor-faktor yang dicerminkan dari variabel dari penelitian terdahulu dan beberapa variabel baru yang menurut peneliti diduga sehingga dapat digunakan untuk prediksi atas Kualitas LKKL. Sehingga riset ini mampu (1) melakukan *exploratory data* faktor apa saja yang berpengaruh kuat terhadap kualitas LKKL; (2) membuat *modelling* klasifikasi untuk memperoleh prediksi kualitas LKKL; (3) memberikan rekomendasi sebagai mitigasi risiko dari hasil *modelling*/prediksi untuk memperkuat level pembinaan akuntansi kepada Kementerian Negara/Lembaga. Oleh karenanya penelitian ini dapat bermanfaat dalam memberikan support bagi penentuan langkah dan strategi yang akan diambil dalam mitigasi resiko atas pencapaian kualitas LKKL. Sebab, turunnya kualitas LKKL tentu akan berdampak pada turunnya kredibilitas Kementerian Keuangan sebagai Pembina/*Lead* Pengelola Keuangan Pemerintah Pusat.

TINJAUAN LITERATUR

Teori Keagenan (*Agency Theory*)

Dalam organisasi sektor swasta maupun sektor publik, masalah keagenan dapat terjadi (Zimmerman, 1977). Dalam konteks pemerintahan, posisi rakyat sebagai prinsipal yang kemudian mendelegasikan wewenangnya kepada pemerintah sebagai agen untuk mengelola sumber

daya yang dimiliki oleh rakyat. Sari A.P. (2016) menyatakan bahwa Pemerintah memiliki akses langsung terhadap informasi, namun tidak demikian dengan rakyat, maka disinilah timbul asimetri informasi.

Asimetri informasi berkaitan dengan biaya keagenan atau biaya yang harus dikeluarkan supaya baik principal maupun agen sama-sama mendapatkan manfaat yang setara. Keberadaan dan besarnya biaya keagenan tergantung salah satunya pada sejauh mana biaya monitoringnya, dan apabila Biaya monitoringnya nol maka Biaya keagenan menjadi nol pula (Jensen and Meckling, 1976). Oleh sebab itu, demi efektivitas dan efisiensi dalam berbangsa dan bernegara, maka akuntabilitas yang dicerminkan dengan kualitas laporan keuangan menjadi syarat mutlak dan kredibilitas pemerintah selaku agen dapat dipercaya principal.

Opini

Berpedoman pada Buletin Teknis Nomor 01 Pelaporan Hasil Pemeriksaan Atas Laporan Keuangan Pemerintah paragraf 13 tentang Jenis Opini. Terdapat empat jenis opini yang dapat diberikan pemeriksa BPK terhadap laporan keuangan, yaitu sebagai berikut:

1. Wajar Tanpa Pengecualian/*Unqualified Opinion* (WTP)
Memuat suatu pernyataan bahwa laporan keuangan menyajikan secara wajar, dalam semua hal yang material sesuai dengan Standar Akuntansi Pemerintahan (SAP).
2. Wajar Dengan Pengecualian/*Qualified Opinion* (WDP)
Suatu pernyataan bahwa laporan keuangan menyajikan secara wajar, dalam semua hal yang material

sesuai dengan SAP kecuali untuk dampak hal-hal yang berhubungan dengan yang dikecualikan.

3. Tidak Wajar/*Adverse Opinion* (TW)
Membuat suatu pernyataan bahwa laporan keuangan tidak menyajikan secara wajar dalam semua hal yang material sesuai dengan SAP.
4. Pernyataan Tidak Memberikan Opini atau Tidak Memberikan Pendapat/*Disclaimer of Opinion* (TMP)
Menyatakan bahwa pemeriksa tidak menyatakan opini atas laporan keuangan.

Penyusunan laporan keuangan merupakan tanggung jawab entitas, sedangkan BPK bertanggung jawab pada pemberian pendapat/opini atas laporan keuangan tersebut berdasarkan hasil pemeriksaan yang dilakukan oleh auditor/pemeriksa secara independen, objektif dan memiliki integritas yang tinggi.

Ukuran Kementerian Negara/Lembaga

Penelitian Nuraeni (2014) menunjukkan bahwa total aset berpengaruh negatif dan signifikan terhadap kualitas audit dari sisi opini audit. Hubungan negatif antara total aset dengan kualitas audit dapat disebabkan oleh pengelolaan aset pemerintah daerah yang masih belum terlaksana dengan baik. Hal ini diindikasikan dengan jumlah temuan audit yang terkait dengan manajemen aset yang menimbulkan kerugian yang tidak kecil. Sehingga semakin banyak aset yang dimiliki pemda, semakin besar juga kemungkinan penyalahgunaannya.

Penelitian tersebut dapat digunakan sebagai landasan untuk melakukan penelitian serupa pada Kementerian Negara/Lembaga, dimana

ukuran Kementerian Negara/Lembaga selain diprosikan melalui total asetnya, dapat juga dilihat dari anggaran dan realisasi belanjanya, termasuk jumlah DIPA.

Indikator Kinerja Pelaksanaan Anggaran (IKPA)

Berdasarkan Perdirjen No. 4/PB/2021, IKPA adalah indikator yang ditetapkan oleh Kementerian Keuangan selaku BUN untuk mengukur kualitas kinerja pelaksanaan anggaran belanja Kementerian Negara/Lembaga, yang meliputi aspek:

1. Kesesuaian antara Perencanaan dengan Pelaksanaan Anggaran
 - a. Revisi DIPA
 - b. Deviasi Halaman III DIPA
 - c. Pagu Minus.
Dihitung dari rasio antara total nilai pagu minus terhadap pagu DIPA. Pagu Minus merupakan realisasi anggaran yang melebihi pagu DIPA pada level akun.
2. Kepatuhan Terhadap Peraturan Perundang-undangan di Bidang Pelaksanaan Anggaran, terdiri dari:
 - a. Penyampaian Data Kontrak
Dihitung dari rasio ketepatan waktu penyampaian data perjanjian/kontrak yang didaftarkan ke KPPN.
 - b. Pengelolaan Uang Persediaan (UP) dan Tambahan Uang Persediaan (TUP)
Dihitung dari rasio ketepatan waktu penyampaian pertanggungjawaban UP Tunai dan TUP Tunai terhadap seluruh pertanggungjawaban UP Tunai dan TUP Tunai.
 - c. Penyampaian Laporan Pertanggungjawaban (LPJ) Bendahara

Dihitung dari rasio penyampaian LPJ Bendahara Pengeluaran yang dilakukan secara tepat waktu terhadap seluruh kewajiban penyampaian LPJ.

d. Dispensasi Penyampaian Surat Perintah Membayar (SPM)

Dihitung dari jumlah SPM yang mendapatkan dispensasi keterlambatan penyampaian SPM melebihi batas waktu penyampaian SPM yang ditentukan pada akhir tahun anggaran.

3. Efektivitas Pelaksanaan Anggaran

a. Penyerapan Anggaran

b. Penyelesaian Tagihan

Dihitung dari rasio ketepatan waktu penyelesaian tagihan dengan mekanisme SPM-LS Kontraktual terhadap seluruh SPM-LS Kontraktual yang diajukan ke KPPN.

c. Capaian Output

d. Retur Surat Perintah Pencairan Dana (SP2D).

4. Efisiensi Pelaksanaan Anggaran

a. Pengembalian/Kesalahan SPM

Dihitung dari rasio antara pengembalian/kesalahan SPM oleh KPPN terhadap seluruh SPM yang diajukan oleh Satker ke KPPN.

b. Perencanaan Kas (Renkas)

Baiknya kualitas pelaksanaan anggaran akan tercermin juga dalam kualitas Laporan Keuangan. Mengingat dalam penelitian ini akan menganalisis klasifikasi kualitas Laporan Keuangan maka tidak semua indikator kinerja tersebut digunakan sebagai variabel.

Umur Kementerian Negara/Lembaga

Penelitian Sari A. P. (2016) menunjukkan bahwa variabel umur organisasi pemerintah berpengaruh negatif terhadap perolehan opini audit. Hal ini menandakan bahwa semakin lama organisasi berdiri maka kemungkinan organisasi tersebut mengalami kesulitan dalam menyajikan laporan keuangan karena tidak dapat mengimplementasikan peraturan terbaru dalam penyajian laporan keuangan dengan baik sehingga opini menjadi buruk.

Karakteristik Pimpinan Kementerian Negara/Lembaga

Pimpinan Kementerian Negara/Lembaga selaku *Chief Operating Officer* bertanggungjawab langsung atas Kementerian Negara/Lembaga yang dipimpinnya termasuk dalam berbagai proses pengambilan keputusan. Secara langsung maupun tidak langsung tentunya juga akan berimplikasi pada kualitas Laporan Keuangan yang disusun. Karakteristik pimpinan Kementerian Negara/Lembaga ini dapat dilihat dari:

1. Tingkat dan Jenis Pendidikan

Penelitian Wicaksono (2012) dalam Sari A. P. (2016) menyatakan bahwa pemerintah daerah yang memiliki kepala daerah dengan latar belakang akuntansi akan mendorong pemerintah daerah untuk dapat menyajikan laporan keuangan yang berkualitas sehingga meningkatkan opini audit.

2. Afiliasi dengan Partai Politik

Hasil penelitian Cheng (1992) menyatakan bahwa tingkat pengungkapan dalam Laporan Keuangan dipengaruhi oleh lingkungan politik.

Temuan

Menurut Bastian (2013) dalam Munawar et al. (2016) temuan adalah hasil audit yang menjelaskan tentang semua informasi penting yang berkaitan dengan masalah audit tertentu.

1. Temuan atas Audit Sistem Pengendalian Intern (SPI)

Hasil audit yang menjelaskan semua hal yang berkaitan dengan kelemahan dalam pengendalian intern atas pelaporan keuangan yang dianggap sebagai kondisi yang dapat dilaporkan.

2. Temuan atas Audit Kepatuhan terhadap Peraturan Perundang-Undangan

Hasil audit yang memverifikasi dan memeriksa bahwa pengeluaran-pengeluaran untuk pelayanan masyarakat telah disetujui dan telah sesuai dengan peraturan perundangan.

Hasil penelitian Munawar et.al. (2016) menunjukkan bahwa jumlah temuan audit atas SPI dan jumlah temuan audit kepatuhan peraturan perundang-undangan berpengaruh negatif terhadap opini atas LKPD.

Tindak Lanjut Atas Rekomendasi BPK

Koreksi setelah proses audit merupakan suatu bentuk tanggung jawab dari Kementerian Negara/Lembaga atas kesalahan dalam pertanggungjawaban keuangan publik. Hasil penelitian Sari A. P. (2016) menunjukkan bahwa terdapat pengaruh tidak langsung yang positif dan signifikan tindak lanjut hasil pemeriksaan terhadap opini audit melalui tingkat pengungkapan laporan keuangan. Semakin banyak rekomendasi BPK yang ditindaklanjuti sesuai rekomendasi akan meningkatkan

kualitas laporan keuangan Kementerian Negara/Lembaga yang tercermin dari tingkat pengungkapan yang tinggi sehingga peluang opini yang diperoleh Kementerian Negara/Lembaga semakin baik.

Fraud dengan Indikasi Korupsi

Association of Certified Fraud Examiner (ACFE) mengklasifikasikan *fraud* ke dalam tiga cabang besar, yaitu penyimpangan atas aset, asersi yang menipu, dan korupsi (Priantara 2013 dalam Didi dan Kesuma (2018)). Dari ketiga cabang jenis *fraud* yang ada, korupsi merupakan jenis *fraud* yang paling banyak dijumpai pada sektor publik. *Fraud* ini dapat ditemukan dalam temuan BPK sebagaimana tertuang pada Laporan Hasil Pemantauan (LHP). *Fraud* korupsi dibedakan menjadi Kas dan Non Kas.

Machine Learning

Machine Learning adalah model statistic atau algoritma yang mempunyai fungsi dalam melakukan tugas spesifik tanpa suatu instruksi dengan mengandalkan sebuah pola atau *pattern* tertentu (Sanjaya, et al. 2020). *Machine learning* terbagi menjadi dua, yakni *unsupervised* dan *supervised learning*. *Unsupervised learning* bekerja dengan cara menemukan pola atau fitur lalu mengkategorikan hasilnya sebagai sebuah prediksi. Berbeda, *supervised learning* bekerja dengan menggunakan data yang mengandung input dan output yang diinginkan. Bentuk umum dari *supervised learning* yakni klasifikasi dan regresi.

Random Forest Algorithm

Klasifikasi merupakan bagian dari model *machine learning* yang bekerja

dengan cara melihat data dan mengelompokkan data berdasarkan kecenderungan data tersebut. Random forest layaknya sebuah kombinasi dari pohon prediktor yang sedemikian rupa sehingga setiap pohon bergantung pada nilai dari sampel *vector* acak secara independen dan dengan distribusi yang sama untuk semua pohon (Breiman, 2001). Lebih lanjut, Breiman (2001) dalam Primajaya dan Sari (2018) menyatakan bahwa *random forest* dipilih karena menghasilkan kesalahan yang lebih rendah, memberikan akurasi yang bagus dalam klasifikasi, dapat menangani data pelatihan yang jumlahnya sangat besar, dan efektif untuk mengatasi data yang tidak lengkap.

Penelitian menggunakan *random forest* telah dilakukan oleh para peneliti sebelumnya. Dhawangkhar (2017) membuat aplikasi prediksi intensitas hujan yang memberikan akurasi tinggi atas hasil prediksi intensitas hujan dengan 5 kemungkinan yakni tidak hujan, ringan sedang, deras, sangat deras. Primajaya dan Sari (2018) mencoba menguji implementasi *random forest*, dan ditemukan bahwa *random forest* mampu menghasilkan model prediksi hujan serta penggunaan Teknik penentuan *training data* dan *testing data* menggunakan keseluruhan data mampu menghasilkan model yang lebih baik dibandingkan dengan teknik pembagian data *k-fold cross validation*. Sejalan, Sanjaya, et al. (2020) juga menggunakan *random forest* dalam memprediksi kelalaian pinjaman bank dengan alasan bahwa *random forest algorithm* mampu berjalan efisien pada data yang jumlahnya banyak dan memiliki akurasi yang tinggi dibandingkan algoritma lainnya dan

mampu berjalan dengan baik pada kelas yang populasinya tidak seimbang.

Decision Tree Algorithm

Nama lain dari *decision tree* adalah CART (*Classification and Regression Tree*). Dimana metode ini merupakan suatu metode nonparametric untuk keperluan klasifikasi dengan cara membangun sebuah pohon klasifikasi yang diperoleh melalui penyekatan berulang terhadap suatu himpunan data menjadi sebuah simpul/*node* baru. CART ini menggunakan algoritma penyekatan rekursif secara biner (*binary recursive partitioning*) (R. J. Lewis, 2000). CART akan menghasilkan pohon klasifikasi jika variabel respon berskala kategorik dan akan menghasilkan pohon regresi jika variabel respon berupa data kontinu.

Penelitian menggunakan *decision tree* telah dilakukan oleh para peneliti sebelumnya. W Yogi Yusuf (2007) melakukan perbandingan performa algoritma *decision tree* C5.0, CART, CHAID, dan C4.5 untuk Kasus Prediksi Status Resiko Kredit Di Bank X dan dapat memberikan tingkat keakuratan di kisaran angka 87%. Budi Setiadi (2015) juga menerapkan algoritma *decision tree* C4.5 untuk penilaian rumah tunggal dan mendapatkan akurasi 72,73% dalam penilaian agunan kredit. Hasil ini ia nyatakan lebih akurat daripada k-NN, *Random Tree*, *Naive Bayes* dan CART.

Support Vector Machine (SVM) Algorithm

Support Vector Machine (SVM) adalah salah satu metode yang bisa digunakan dalam proses klasifikasi atau regresi. Metode SVM dapat mengklasifikasikan masalah secara *linier*, namun saat ini SVM sudah

berkembang dan dapat menyelesaikan masalah secara *non-linier* dengan mencari *hyperlane* yang digunakan untuk jarak maksimal antar kelas data (Oktaviani, Wulandari, & Ispriyanti, 2014). SVM merupakan metode yang bersifat *non-parametric* dan biasanya digunakan dalam klasifikasi data serta pengolahan citra. Tingkat akurasi pada metode ini diambil dari parameter dan *kernel*, pengguna dapat menentukan parameter dan pada *kernel* setiap parameter akan memiliki dampak yang berbeda (Ustuner, Samli, & Dixon, 2015).

Penelitian menggunakan SVM telah dilakukan oleh para peneliti sebelumnya. Weni Agustina, et al. (2018) menggunakan SVM untuk Klasifikasi Rumah Layak Huni pada studi kasus Desa Kidal, Kec. Tumpang, Kab. Malang. Selain itu, Fathurrahman dan Yupi Kuspani Putra (2021) juga menggunakan SVM untuk Analisis Perbandingan Pengaruh Pertumbuhan Ekonomi terhadap Tingkat Kesejahteraan Masyarakat pada Desa Suralaga.

Naïve Bayes Algorithm

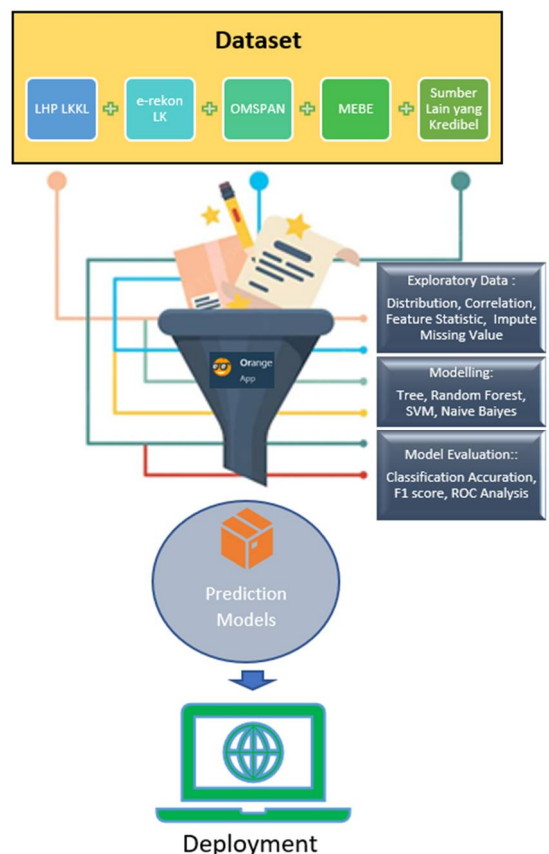
Bayesian classification adalah pengklasifikasian statistic yang dapat digunakan untuk memprediksi probabilitas keanggotaan suatu *class*. *Bayesian classification* didasarkan pada teorema Bayes yang memiliki kemampuan klasifikasi serupa dengan *decision tree* dan *neural network*. *Bayesian Classification* terbukti memiliki akurasi dan kecepatan yang tinggi saat diaplikasikan ke dalam database dengan data yang besar (Supriyanto, Catur. Purnama Parida, 2013).

Penelitian menggunakan *Naïve Bayes* telah dilakukan oleh para peneliti sebelumnya. Haditsah Annur (2018)

menggunakan metode *naïve bayes* untuk mengklasifikasikan masyarakat miskin pada Kecamatan Tibawa, Kab. Gorontalo dengan tingkat akurasi 73%, nilai *Precision* 92%, dan *Recall* 86%. Sejalan dengan itu, Artika Surniandari, Hilda Rachmi, dan Lisda Widiastuti (2022) juga menggunakan *Naïve Bayes* untuk mengklasifikasikan penduduk dengan tingkat ekonomi rendah pada Kecamatan Pasar Babakan Bogor dengan hasil pengujian menunjukkan akurasi 100%, *precision* 100%, dan *recall* 100%.

METODOLOGI PENELITIAN

Research Design



Perancangan penelitian ini menggunakan proses sistematis dari alur kerja *machine learning*. Alur kerja *machine learning* secara umum terdiri dari 4 langkah yaitu, *data exploration*, *data cleaning*, *model building*, dan *presenting the results*. Setiap langkah terdiri dari setidaknya satu proses. Sebagai contoh, data *visualization* dan *finding the outliers* adalah proses-proses dalam langkah *data exploration*. Alur kerja *machine learning* dapat dilihat pada gambar berikut. Adapun penelitian ini merupakan penelitian kuantitatif dengan *machine learning* untuk memperoleh prediksi klasifikasi dari beberapa pilihan model yang akan diproses/dijalankan.

Sumber Data dan Variabel

Penelitian ini menggunakan data sekunder sepanjang tahun 2018-2020 dari jumlah sampel Kementerian Negara/Lembaga (K/L) per tahun sebagai berikut:

- Tahun 2018 : 86 K/L
- Tahun 2019 : 87 K/L
- Tahun 2020 : 86 K/L

Data diperoleh dari berbagai sumber. Diantaranya dari berkas arsip yang disediakan secara internal Direktorat Akuntansi dan Pelaporan Keuangan, sistem dan aplikasi yang disediakan oleh Direktorat Jenderal Perbendaharaan, dan sumber lainnya. Adapun rincian sumber data yang kami peroleh adalah sebagai berikut:

1) Data Opini LKKL

Data ini merupakan data yang akan dipakai sebagai output dari prediksi. Data terdiri dari klasifikasi opini WTP, WDP, TMP, dan TW seluruh LKKL dari tahun 2018-2020 dan bersumber dari Laporan Hasil Pemeriksaan BPK atas

Laporan Keuangan Kementerian Negara / Lembaga.

2) Data Aset (AST)

Data ini merupakan data total aset tiap Kementerian Negara / Lembaga dari tahun 2018-2020 yang diambil melalui Laporan Keuangan Neraca pada aplikasi e-rekon-LK di alamat e-rekon-lk.kemenkeu.go.id.

3) Data Anggaran (ANG)

Data ini merupakan data total anggaran tiap Kementerian Negara / Lembaga dari tahun 2018-2020 yang diambil melalui Laporan Realisasi Anggaran (LRA) pada aplikasi e-rekon-LK di alamat e-rekon-lk.kemenkeu.go.id.

4) Data Penyerapan

Data ini diformulasikan dari persentase realisasi terhadap anggaran tiap Kementerian Negara / Lembaga dari tahun 2018-2020 yang diambil melalui Laporan Realisasi Anggaran (LRA) pada aplikasi e-rekon di alamat e-rekon-lk.kemenkeu.go.id.

5) Jumlah DIPA

Data ini merupakan total DIPA satker yang dikelola Kementerian Negara/ Lembaga. DIPA satker diidentifikasi pada 3 digit kode BA tiap SP-DIPA memiliki kode yang sama dengan kode Bagian Anggaran Kementerian Negara / Lembaga. Data diambil dari Laporan Keuangan Kementerian Negara / Lembaga dan aplikasi MEBE (Monitoring and Evaluation of Budget Execution) yang dikelola oleh Direktorat Pelaksanaan Anggaran, DJPb.

6) Data IKPA

Merujuk pada Perdirjen Perbendaharaan nomor PER-4/PB/2021 tentang Petunjuk Teknis Penilaian Indikator Kinerja

Pelaksanaan Anggaran Belanja Kementerian Negara/Lembaga, Indikator Kinerja Pelaksanaan Anggaran (IKPA) adalah indikator yang ditetapkan oleh Kementerian Keuangan selaku BUN untuk mengukur kualitas kinerja pelaksanaan anggaran belanja Kementerian Negara/Lembaga dari sisi kesesuaian terhadap perencanaan, efektivitas pelaksanaan anggaran, efisiensi pelaksanaan anggaran, dan kepatuhan terhadap regulasi. Berdasarkan pemantauan kami pada LHP BPK tahun 2018-2020, temuan dan rekomendasi BPK secara umum bersinggungan dengan komponen IKPA berikut:

- a) Pagu Minus (PGMIN)
- b) Data Kontrak (KONT)
- c) UP/TUP (UP/TUP)
- d) LPJ (LPJ)
- e) Dispensasi SPM (DSPM)
- f) Penyelesaian Tagihan (TAG)
- g) Kesalahan SPM (SPM)

Seluruh data komponen IKPA tahun 2018-2020 bersumber dari aplikasi OMSPAN pada fitur Monev-PA di alamat spanint.kemenkeu.go.id.

- 7) Umur Kementerian Negara/Lembaga
Data ini diperoleh dari Laporan Keuangan Kementerian Negara/Lembaga tahun 2018-2020 pada bagian A.1. Profil dan Kebijakan Teknis. Selain itu, apabila informasi tersebut tidak bisa kami dapat pada Laporan Keuangan, kami mengambilnya dari situs resmi Kementerian Negara / Lembaga.
- 8) Karakteristik Pimpinan Kementerian Negara/ Lembaga
Data ini diambil dari Laporan Keuangan Kementerian Negara/Lembaga tahun 2018-2020, terutama

dengan melihat pencantuman gelar pendidikan dan NIP Pengguna Anggaran. Adapun karakteristik pimpinan Kementerian Negara/Lembaga yang menjadi variabel adalah sebagai berikut:

a) Tingkat Pendidikan

Diambil dari pencantuman gelar pada nama Pengguna Anggaran, kemudian diklasifikasikan menjadi Non-Sarjana, Sarjana (S1), Magister (S2), Doktor (S3).

b) Jenis Pendidikan

Diambil dari pencantuman gelar pada nama Pengguna Anggaran, kemudian diklasifikasikan menjadi pendidikan ekonomi/akuntansi dan selain ekonomi/akuntansi.

c) Afiliasi Partai Politik

Data diklasifikasikan menjadi Afiliasi Partai Politik dan Non Afiliasi Partai Politik. Diambil dari berbagai sumber berita yang kredibel. Namun apabila Pengguna Anggaran adalah ASN atau PPPK, maka data langsung ditentukan adalah Non Afiliasi Partai Politik.

9) Jumlah Temuan

Data ini diambil dari Laporan Hasil Pemeriksaan (LHP) BPK tahun 2018-2020. Adapun temuan dari BPK berdasarkan LHP dibedakan menjadi dua, yaitu:

- Temuan SPI
- Temuan Kepatuhan terhadap Peraturan Perundang-undangan

10) Persentase Tindak Lanjut atas Rekomendasi BPK

Data ini diambil dari Laporan Hasil Pemeriksaan (LHP) BPK tahun 2018-2020. Kemudian data rekomendasi yang telah sesuai ditindaklanjuti oleh Kementerian Negara / Lembaga

dibagi dengan jumlah rekomendasi BPK. Jumlah rekomendasi dihitung dari 1 tahun sebelum tahun LHP hingga tahun 2014. Sebagai contoh, untuk data persentase tindak lanjut dari LHP BPK tahun 2019, dihitung dari jumlah rekomendasi yang telah sesuai ditindaklanjuti dari tahun 2014-2018 dibagi dengan jumlah rekomendasi BPK dari tahun 2014-2018.

11) *Fraud* dengan Indikasi Korupsi

Data ini diambil dari Laporan Hasil Pemeriksaan (LHP) BPK tahun 2018-2020. Data ini kemudian dibedakan menjadi Kas dan Non-kas. Kas adalah data fraud yang melibatkan uang yang berada dalam pengawasan Bendahara seperti UP, TUP, dan LS Bendahara. Selain daripada itu dikategorikan sebagai Non-kas.

Dari sumber data tersebut diatas variabel target yang di gunakan yaitu Kualitas LK yaitu data Opini atas audit BPK. Sedangkan variabel *feature* yang digunakan untuk *predictor* yaitu:

Tabel. 2 Variabel Penelitian

VARIABEL TARGET	
Y	Opini Audit LKKL
VARIABEL FEATURE (PREDICTOR)	
X₁	Aset
X₂	Anggaran
X₃	Realisasi
X₄	Jumlah DIPA
X₅	Pagu Minus
X₆	Kontrak
X₇	UP/TUP
X₈	LPJ
X₉	Penyerapan
X₁₀	TAG
X₁₁	SPM
X₁₂	Afiliasi Politik

X₁₃	Tk. Pendidikan Pim
X₁₄	Jenis Pendidikan Pim
X₁₅	Umur Lembaga
X₁₆	Fraud Kas
X₁₇	Fraud Non Kas
X₁₈	Deviasi SPM
X₁₉	Temuan SPI
X₂₀	Temuan UU
X₂₁	Tindak Lanjut SPI
X₂₂	Tindak Lanjut UU
X₂₃	Temuan (Gabungan)
X₂₄	Tindak Lanjut (Gabungan)

Tahapan Permodelan *Machine Learning*

Prediksi dan Permodelan disini menggunakan aplikasi Orange atau dikenal juga dengan sebutan Orange Data Mining yang merupakan salah satu perangkat lunak *open source* yang dapat melakukan suatu tahapan *data mining* atau *data analytic* dengan konsep visual *programming* sehingga lebih mudah bagi peneliti yang tidak memiliki dasar pemrograman/IT.

Pada Proses penelitian ini terdapat beberapa tahapan analisis yang dilakukan, yaitu sebagai berikut:

1. *Exploratory Data*, yaitu merupakan bagian statistika deskriptif guna mencari informasi umum seperti korelasi dan distribusi data guna menentukan variabel mana saja yang paling tepat digunakan sebagai *feature/predictor*.
2. *Data Preparation*, yaitu mempersiapkan data yang akan di estimasi dalam permodelan. Pada tahap ini dilakukan pemilihan variabel berdasarkan tahapan sebelumnya salah satunya yaitu korelasi. Pada tahap ini korelasi antar

variabel *feature/predictor* dipakai untuk menentukan multikolinearitas dalam data, dimana menurut Gujarati (2007) korelasi dengan nilai diatas 0,8 terindikasi gejala multikolinearitas. Selain itu juga dilakukan pengisian atas *missing value* pada data yang bisa mengganggu hasil permodelan. Menurut Sarkodie dan Owusu (2020), pengisian *missing value* pada Orange dapat dilakukan dengan 6 teknik yaitu:

- a. *Don't Impute* (tidak diisi)
- b. *Average/Most Frequent* (dengan rata-rata/ nilai yang sering muncul)
- c. *As a distinct value* (membuat nilai-nilai baru untuk menggantikan yang hilang)
- d. *Random Values* (pengisian acak oleh machine)
- e. *Remove Examples* (menghapus raw data yang kosong)

Mempertimbangkan jenis pola data peneliti memilih teknik *Average/Most Frequent* untuk mengatasi *missing values*.

2. *Modelling*, yaitu tahapan permodelan prediksi klasifikasi. Pada tahap ini digunakan Teknik random sampling dan pembagian dataset serta pengulangan pengujian data (repeat train/test).
3. *Model evaluation*, yaitu untuk mengetahui kinerja dari masing-masing model klasifikasi dengan membandingkan test and score dari beberapa model yang digunakan untuk dipilih satu model terbaik, model terpilih kemudian disimpan dalam pickled models (.pkl).
4. *Deployment*, yaitu tahapan lebih lanjut yang bertujuan menggunakan model terpilih untuk simulasi

prediksi. Deployment aplikasi simulasi dilakukan dengan menggunakan Streamlit. Simulasi dilakukan dengan mengisi asumsi atas variabel-variabel yang mempengaruhi target sesuai kondisi Kementerian Negara / Lembaga, kemudian akan dihubungkan dengan model terpilih (pickled models) yang menghasilkan prediksi Kualitas Laporan Keuangan suatu Kementerian Negara/Lembaga.

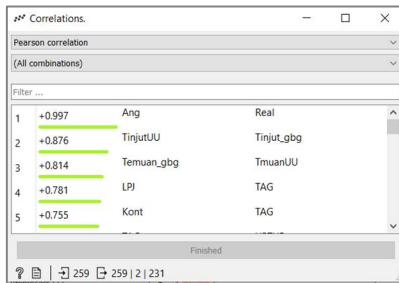
HASIL PENELITIAN DAN PEMBAHASAN

Sebagaimana dijelaskan pada bagian sebelumnya, proses pengolahan *data analytics* pada penelitian ini dilakukan dengan menggunakan aplikasi Orange. Gambaran proses pada aplikasi Orange sebagaimana pada Lampiran. Proses yang telah dilakukan meliputi beberapa tahapan yaitu *Exploratory Data*, *Data Preparation*, *Modelling* dan *Model Evaluation*.

Exploratory Data

Sesuai hasil olah data dengan menggunakan aplikasi Orange. Dilakukan eksplorasi terhadap hubungan antar variabel *feature/predictor*. Hal ini bertujuan untuk menghindarkan model dari adanya multikolinearitas yang dapat mengganggu akurasi model. Berdasarkan hasil korelasi diketahui bahwa terdapat variabel yang memiliki nilai korelasi diatas 0,8 yaitu:

Gambar 2. Uji Korelasi



Sumber: Olah data Orange

Dari hasil korelasi diatas peneliti memutuskan untuk mengeluarkan beberapa variabel yaitu Anggaran dan Temuan UU dikarenakan memiliki nilai korelasi diatas 0,8. Pada tahap ini peneliti membuat variabel baru yaitu penyerapan yang didapat dari Realisasi dibagi Anggaran melalui *feature constructor*. Selain itu berdasarkan penelusuran *missing value* diketahui pada data terdapat 3,1% *missing* data yang dapat diketahui pada info Data Table di Orange.

Setelah dilakukan penelusuran pada *dataset*, diketahui bahwa *missing value* tersebut banyak terdapat pada variabel temuan SPI dan tindak lanjut atas rekomendasi temuan SPI tahun 2020, hal ini karena pada tahun 2020 temuan SPI dan tindak lanjut atas rekomendasi temuan SPI pada LHP BPK digabung dengan temuan UU dan tindak lanjut atas rekomendasi temuan UU, sehingga peneliti membuat satu variabel baru yaitu temuan gabungan dan tindak lanjut atas rekomendasi temuan gabungan yang selanjutnya disebut tindak lanjut atas rekomendasi BPK, serta mengeluarkan variabel pembentuknya.

Data Preparation

Berdasarkan informasi yang diperoleh pada tahap *Exploratory Data*, pada tahap ini di lakukan pemilihan variabel sebagai *feature/predictor* yang kemudian dijadikan dasar pembentukan dataset yang akan diproses/dijalankan. Variabel yang dikeluarkan antara lain variabel Anggaran, variabel Deviasi SPM, variabel Temuan UU, variabel Tindak Lanjut atas rekomendasi temuan UU, variabel temuan SPI, dan variabel tindak lanjut atas rekomendasi temuan SPI. Hal ini perlu dilakukan oleh peneliti untuk mendukung proses permodelan dan menghindari hasil yang bias. Pada tahap ini juga dilakukan penginputan *missing value* (data kosong) dengan memilih metode *average/most frequent*, dengan demikian diharapkan estimasi model dapat optimal.

Modelling

Permodelan *machine learning* pada penelitian ini dilakukan terhadap beberapa model untuk prediksi klasifikasi yaitu *Decision Tree*, *Random Forrest*, *Support Vector Machine*, dan *Naive Baiyes*. Kemudian proses *sampling* untuk *learner model* menggunakan teknik *Random Sampling* yaitu teknik membagi data secara acak ke dalam data *Train* dan data *Test* dengan proporsi tertentu (misalnya 70:30), kemudian seluruh prosedur diulang untuk beberapa kali tertentu dan dapat dilakukan secara *stratified*. Pada penelitian ini dilakukan dengan pengulangan atau *Repeat Train/Test* sebanyak 20 kali dan pembagian data *Train* dan data *Test* sebesar 70:30. Teknik *Random sampling* tersebut dilakukan juga secara bertingkat (*Stratified*) untuk mendapatkan hasil maksimal.

Model Evaluation

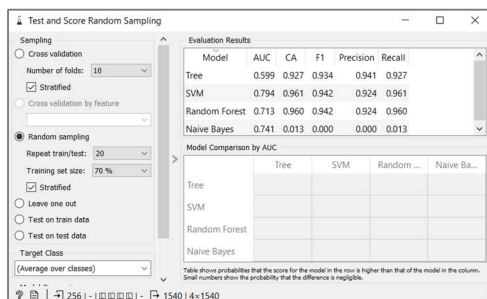
Selanjutnya Evaluasi model klasifikasi difokuskan terhadap beberapa hal yaitu:

- Classification Accuracy* merupakan proporsi hasil estimasi yang diklasifikasikan dengan benar.
- F1 Score* merupakan *harmonic mean* tertimbang dari nilai *precision* dan nilai *recall*.

Mengingat bahwa jumlah non-WTP jumlahnya sedikit, maka dalam menentukan model terpilih peneliti menekankan juga proporsi true negatif di antara semua estimasi negatif, misal. jumlah yang tidak sakit di antara semua yang didiagnosis tidak sakit. Hal ini penting mengingat penelitian ini bertujuan untuk mitigasi resiko penurunan Kualitas LK. Jadi peneliti sangat memperhatikan hasil prediksi untuk kategori WDP dan TMP.

Adapun hasil *test and score* atau evaluasi dari permodelan sebagai berikut:

Gambar 4. *Evaluasi Model*

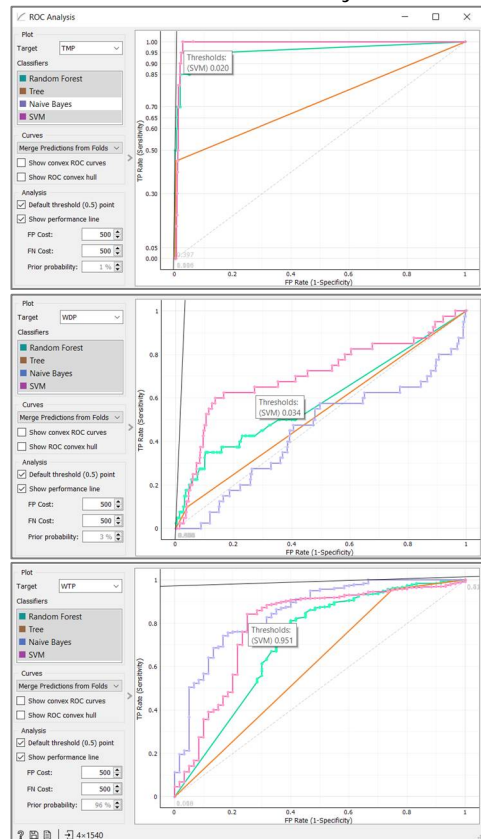


Sumber: Olah data Orange

Berdasarkan hasil evaluasi model terlihat SVM memiliki nilai Akurasi Klasifikasi (CA) dan F1 yang lebih baik dibandingkan tiga model lainnya yaitu *Tree*, *Random Forest* dan *Naive Baiyes*. Selanjutnya untuk melihat lebih detail dan berfokus pada WDP dan TMP

sebagai bagian dari mitigasi resiko dilakukan analisis ROC dengan hasil sebagai berikut:

Gambar 5. ROC Analysis



Sumber: Olah data Orange

Terlihat bahwa garis SVM pada ROC analysis lebih baik yang selalu berada paling atas mendekati angka 1. Bahkan untuk kategori WDP dan TMP yang jumlah datanya sedikit, model SVM lebih baik dibandingkan model yang lain.

Variabel paling berpengaruh

Selain mendapat model yang paling baik dalam memprediksi klasifikasi kualitas LKKL, perlu juga di ketahui variabel-variabel mana saja yang paling berpengaruh terhadap kualitas LKKL. Hal ini dapat dimanfaatkan dalam mitigasi resiko atas target Kualitas LKKL dan focus pembinaan Akuntansi


Kementerian Lembaga. Aplikasi Orange juga dilengkapi dengan beberapa *Tools* untuk mencari Variabel yang berpengaruh dari dataset yang digunakan. Berikut beberapa *Tools* yang dipilih peneliti dalam mengetahui Variabel yang berpengaruh terhadap Kulaitas Laporan Keuangan K/L.

Tabel 4. Tabel *Mean Decrease Gini*

	#	Gini
N FraudKas		0.065
N Tem...gbg		0.035
N Tinjut_gbg		0.025
N UPTUP		0.018
N Real		0.016
N LPJ		0.015
N Ast		0.014
N Umur		0.014
N FraudNon		0.013
N Kont		0.010
N PgMin		0.009
N DIPA		0.009
N TkPdkPim		0.008
N TAG		0.006
C JnPdkPim	2	0.005
N SPM		0.005
N Pen...pan		0.004
C PolNonPol	2	0.001

Sumber: Olah data Orange

Gambar 5. *FreeViz*



Sumber: Olah Data Orange

Berdasarkan Tabel *Decrease Gini* dan *FreeViz* diketahui bahwa lima variabel yang paling berpengaruh yaitu *Fraud Kas*, *Temuan (gabungan)*, *Tindak Lanjut atas Rekomendasi BPK*, *UP/TUP* serta *Realisasi*. *Fraud Kas* yang lebih condong pada tindakan korupsi memang relatif berdampak pada citra Lembaga maupun opini auditnya, sebagaimana penelitian Rini dan Sarah (2014) yang menemukan keterkaitan kuat antara korupsi dengan opini yang diberikan oleh BPK RI. Terkait *Temuan* dan *Tindak lanjut atas rekomendasi BPK* yang juga menjadi variabel paling berpengaruh dalam penelitian ini sejalan dengan temuan Sari (2015) yaitu temuan audit, tindak lanjut hasil pemeriksaan berpengaruh terhadap opini audit secara tidak langsung. Berikutnya ada variabel *UP/TUP* dimana seringkali pelanggaran atas ketentuan *UP/TUP* terutama siklus *revolving*, Armin (2018) menemukan bahwa dalam siklus *UP/TUP* masih sering terdapat kesalahan administrasi yang tidak dapat dihindari. Selanjutnya terkait *Realisasi*, yang mana hal tersebut tertuang dalam Laporan *Realisasi Anggaran* dan menjadi salah satu bahan utama audit BPK. Selain itu *Realisasi* juga menjadi cerminan kinerja keuangan Lembaga. Kesalahan penyajian dan kewajaran dalam Laporan *Realisasi* bisa menjadi fatal bagi temuan audit yang dapat mempengaruhi opini audit.

KESIMPULAN DAN SARAN

Berdasarkan hasil pengujian dan pemrosesan melalui teknik *machine learning*, ditemukan bahwa variabel *fraud* kas, temuan (gabungan), tindak lanjut rekomendasi BPK atas temuan (gabungan), UP/TUP, dan realisasi mempunyai pengaruh yang kuat terhadap kualitas laporan keuangan Kementerian Negara/ Lembaga. Berdasarkan variabel-variabel tersebut, maka dalam peningkatan kualitas LKKL, Pemerintah Pusat dapat memfokuskan pada bidang pencegahan atau deteksi dini kemungkinan terjadinya *fraud*. Selain itu agar setiap tindak lanjut atas rekomendasi BPK hendaknya menjadi prioritas dalam setiap pengambilan kebijakan.

Dari beberapa model yang dilakukan pengujian, didapatkan bahwa model *Support Vector Machine* (SVM) mampu membuat prediksi klasifikasi yang lebih baik dengan akurasi 96,1%. Model SVM ini dapat dijadikan *tools* sebagai *early warning system* dalam manajemen pengelolaan akuntansi pemerintahan khususnya kepada Kementerian Negara/Lembaga sekaligus mendukung pengambilan kebijakan baik di Kementerian Keuangan selaku *lead* kebijakan akuntansi pemerintah pusat maupun Kementerian Negara/Lembaga selaku penyusun laporan keuangan. Melalui temuan dan model diatas, diharapkan mampu memberikan rekomendasi dari mitigasi risiko dalam pembinaan akuntansi pemerintah pusat.

IMPLIKASI DAN KETERBATASAN

Hasil penelitian ini diharapkan menjadi salah satu terobosan dalam pengelolaan keuangan negara khususnya bidang pelaporan dan pertanggungjawaban atas pelaksanaan anggaran untuk meningkatkan fungsi analisis dalam akuntansi sehingga memudahkan mitigasi resiko atas keberlangsungan akuntabilitas pemerintah pusat. Namun, walau begitu tak ada gading yang tak retak, maka riset ini pun juga memiliki keterbatasan. Keterbatasan tersebut diantaranya seluruh data yang digunakan merupakan data sekunder dalam tiga tahun dan proses pengujian model menggunakan aplikasi *orange*. Oleh karenanya, dalam penelitian selanjutnya diharapkan dapat menggunakan *mixed method*, yakni menggabungkan antara data sekunder dengan wawancara untuk memperdalam analisis mengenai faktor-faktor yang berpengaruh terhadap kualitas LKKL.

Tahapan *Deployment* belum dapat ditampilkan pada paper ini mengingat keterbatasan waktu dan sumberdaya manusia yang menguasai bahasa pemrograman lebih lanjut dalam hal *deployment* Aplikasi Streamlit. Untuk mendapatkan hasil yang akurat, penelitian yang akan datang dapat melakukan pemrosesan melalui *machine learning* menggunakan *python* sekaligus menambah data pengamatan.

REFERENSI

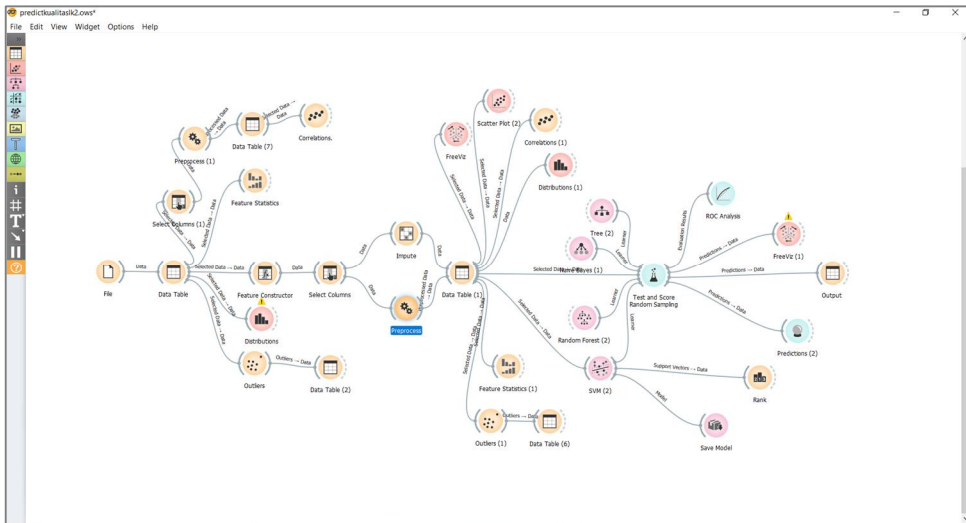
- Annur, Haditsah. (2018). Klasifikasi Masyarakat Miskin Menggunakan Metode Naïve Bayes. *ILKOM Jurnal Ilmiah*, 10(2).
- Armin, K. (2018). Analisis Siklus Pengeluaran Uang Persediaan (UP) pada Kantor Pengawasan Dan Pelayanan Bea dan Cukai TMP B Palembang. *Jurnal Kompetitif*, 7(2).
- Breiman, L. (2001). Random forests. *Machine learning*, 45(1), 5-32.
- Cheng, R. H. (1992). An Empirical Analysis of Theories on Factors Influencing State Government Accounting Disclosure. *Journal of Accounting and Public Policy*, 11(1), 1-42.
- Dhawangkhar, M. (2017). Prediksi Intensitas Hujan Kota Surabaya dengan Matlab menggunakan Teknik Random Forest dan CART (Studi Kasus Kota Surabaya). *Tugas Akhir*. Institut Teknologi Sepuluh Nopember.
- Didi, D., & Kusuma, I. C. (2018). Faktor-Faktor yang Berpengaruh terhadap Kecenderungan Kecurangan (Fraud): Persepsi Pegawai Pemerintahan Daerah Kota Bogor. *Jurnal Akuntansi dan Keuangan Indonesia*, 15(1), 1-20.
- Fathurrahman, Putra, Yupi Kuspandi. (2021). Analisis Perbandingan Pengaruh Pertumbuhan Ekonomi Terhadap Tingkat Kesejahteraan Masyarakat Pada Desa Suralaga dengan Menggunakan Algoritma Naïve Bayes dan Support Vector Machine (SVM). *Jurnal Informatika dan Teknologi*, 4(1).
- Gujarati, D. N. (2007). Dasar-dasar Ekonometrika.
- Jensen, M. C., & Meckling, W. H. (1976). Theory of The Firm: Managerial Behavior, Agency Costs and Ownership Structure. *Journal of Financial Economics*, 3(4), 305-360.
- Jokowi: Opini WTP Bukan Prestasi, tapi Kewajiban.(2017). nasional.okezone.com. <https://nasional.okezone.com/read/2017/12/05/337/1825297/jokowi-opini-wtp-bukan-prestasi-tapi-kewajiban>
- Keputusan Badan Pemeriksa Keuangan Republik Indonesia Nomor 4/K/I-XIII.2/9/2012 tentang Buletin Teknis Nomor 01 Pelaporan Hasil Pemeriksaan Atas Laporan Keuangan Pemerintah. Diakses tanggal 9 Maret 2022 dari <https://www.scribd.com/document/293877898/Buletin-Teknis-No-01-Pelaporan-LHP-atas-LK-Pemerintah>
- Kewo, C. L., & Afiah, N. N. (2017). Does quality of financial statement affected by internal control system and internal audit?. *International Journal of Economics and Financial Issues*, 7(2), 568-573.
- Lewis, R. J. (2000). An Introduction to Classification and Regression Tree (CART). Department of Emergency Medicine Harbor – UCLA Medical Center, Torrance, California.
- Munawar, Nadirsyah, & Abdullah, S. (2016). Pengaruh Jumlah Temuan Audit Atas SPI dan Jumlah Temuan Audit Atas Kepatuhan Terhadap Opini Atas Laporan Keuangan Pemerintah Kabupaten/Kota di Aceh. *Jurnal Magister Akuntansi Pascasarjana Universitas Syiah Kuala*, 5(2), 57-67.

- Nuraeni. (2014). The Impact of Local Governments Characteristics to Audit Quality Indonesia Perspectives. *Finance and Banking Journal*, 16(1), 66-82.
- Nurdiono, N., Sugiri, S., & Halim, A., Gudono, G. (2016). The Effect of Budgets' Proportion and Non-Financial Factors on The Audit Results of Local Governments' Financial Statements in Indonesia. *Journal of Indonesian Economy and Business*, 31(2), 178-191.
- Oktaviani, P.A., Wulandari, Y., & Ispriyanti, D. (2014). Penerapan Metode Klasifikasi Support Vector Machine (SVM) pada Data Akreditasi Sekolah Dasar (SD) di Kabupaten Magelang. *Gaussian*.
- Peraturan Direktur Jenderal Perbendaharaan Nomor PER-4/PB/2021 tentang Petunjuk Teknis Penilaian Indikator Kinerja Pelaksanaan Anggaran Belanja Kementerian Negara/Lembaga. Diakses tanggal 9 Maret 2022 dari <https://jdih.kemenkeu.go.id/in/dokumen/peraturan>
- Peraturan Menteri Keuangan Nomor 215/PMK.05/2016 Perubahan atas Peraturan Menteri Keuangan Nomor 213/PMK.05/2013 Tentang tentang Sistem Akuntansi dan Pelaporan Keuangan Pemerintah Pusat. Diakses tanggal 9 Maret 2022 dari <https://jdih.kemenkeu.go.id/in/dokumen/peraturan>
- Primajaya, A., & Sari, B. N. (2018). Random Forest Algorithm for Prediction of Precipitation. *Indonesian Journal of Artificial Intelligence and Data Mining*, 1(1), 27-31.
- Rini, R., & Sarah, A. (2014). Opini audit dan pengungkapan atas laporan keuangan pemerintah kabupaten serta kaitannya dengan korupsi di Indonesia. *Etikonomi*, 13(1).
- Roni, M., Husnan, L. H., & Fitriah, N. (2019). Determinan Kualitas Laporan Keuangan Satuan Kerja di Wilayah Pembayaran Kantor Pelayanan Perbendaharaan Negara Mataram. *Jurnal Akuntansi Aktual*, 3(2), 175-187.
- Sanjaya, J., Renata, E., & Budiman, V. E., Anderson, F., & Ayub, M. (2020). Prediksi Kelalaian Pinjaman Bank Menggunakan Random Forest dan Adaptive Boosting. *Jurnal Teknik Informatika Dan Sistem Informasi*, 6(1).
- Sari, A. P. (2016). Faktor-Faktor yang Mempengaruhi Opini Audit dengan Tingkat Pengungkapan Laporan Keuangan Kementerian/Lembaga sebagai Variabel Intervening. *Jurnal BPPK: Badan Pendidikan dan Pelatihan Keuangan*, 9(1), 33-46.
- Sari, A. P., Martani, D., & Setyaningrum, D. (2015). Pengaruh temuan audit, tindak lanjut hasil pemeriksaan dan kualitas sumber daya manusia terhadap opini audit melalui tingkat pengungkapan laporan keuangan kementerian/lembaga. *Simposium Nasional Akuntansi XVIII*.
- Sarkodie, S. A., & Owusu, P. A. (2020). How to apply dynamic panel bootstrap-corrected fixed-effects (xtbcsfe) and heterogeneous dynamics (panelhetero). *MethodsX*, 7, 101045.

- Setiadi, Budi. (2015). Penerapan Algoritma Decision Tree C4.5 Untuk Penilaian Rumah Tunggal. *Info Teknik*. 16(2), 195-206.
- Simanungkalit, Alfa MH. (2015). Analisis Determinan Kualitas Laporan Keuangan Kementerian/Lembaga Satuan Kerja di Wilayah Kerja Kantor Pelayanan Perbendaharaan Negara Banda Aceh. *Thesis*. Universitas Sumatera Utara.
- Supriyanto, Catur. Purnama Parida. (2013). Deteksi Penyakit Diabetes Tipe II dengan Naïve Bayes Berbasis Particle Swarm Optimization. *Jurnal Teknologi Informasi*, 9(2).
- Surniandari, Artika. Rachmi, Hilda. Widiastuti, Lisda. (2022). Klasifikasi Penduduk Dengan Tingkat Ekonomi Rendah Menggunakan Metode Klasifikasi Naïve Bayes. *Jurnal Ilmu Komputer dan Sistem Informasi*, 5(1), 34-40.
- Sutaryo, Naviantia, I.A., Muhtar. (2020). Audit Opinion on Government Financial Report: Evidence from Local Government in Indonesia. *International Journal of Economics and Management*. 14 (1): 129-144.
- Ustuner, M., Samli, F. B., & Dixon, B. (2015). Application of Support Vector Machines for Landuse Classification Using High-Resolution RapidEye Images: A Sensitivity Analysis. *European Journal of Remote Sensing*.
- Weni Agustina, Muh. Tanzil Furqon, Bayu Rahayudi. (2018). Implementasi Metode Support Vector Machine (SVM) Untuk Klasifikasi Rumah Layak Huni (Studi Kasus: Desa Kidal Kecamatan Tumpang Kabupaten Malang). *Jurnal Pengembangan Teknologi Informasi dan Ilmu Komputer*, 2(10), 3366-3372.
- Windarsih, D. (2015). Hubungan Kualitas Reviu Laporan Keuangan Dengan Temuan Pemeriksaan BPK pada Pemerintah Kabupaten/Kota se-DIY. *Thesis*. Universitas Gadjah Mada.
- Yusuf W., Yogi. (2007). Perbandingan Performansi Algoritma Decision Tree C5.0, CART, dan CHAID: Kasus Prediksi Status Resiko Kredit di Bank X. *Seminar Nasional Aplikasi Teknologi Informasi 2007 (SNATI 2007)*
- Zimmerman, J. L. (1977). The Municipal Accounting Maze: An analysis of Political Incentives. *Journal of accounting research*, 107-144.

LAMPIRAN

Proses pada Aplikasi Orange



Import dataset

File

Source

File: dataset_opini2.xlsx

Sheet

URL:

Info

256 instance(s)
26 feature(s) (3.1% missing values)
Data has no target variable.
2 meta attribute(s)

Columns (Double click to edit)

	Name	Type	Role	Values
1	BA	numeric	feature	
2	Tahun	numeric	feature	
3	Ast	numeric	feature	
4	Ang	numeric	feature	
5	Real	numeric	feature	
6	DIPA	numeric	feature	
7	Opini	categorical	feature	TMP, WDP, WTP
8	RpMin	numeric	feature	

Reset

Apply

Browse documentation datasets

256

Info Data Table

Data Table

Info

256 instance(s)
26 features (3.1% missing values)
No target variable
2 meta attributes

Variables

Show variable labels (if present)

Show numeric values

Show the instance values

Select

Reset full rows

	K/L	dataset	BA	Tahun	Ast	Ang	Real	DIPA	Opini	PgMin	Real	Opini	Real	Opini
1	Majelis Permusyawaratan Rakyat	1945	1	2018	647879420705.0	1040791480000	89904206218	2	WTP	99.87	95	95	150	95
2	Dewan Perwakilan Rakyat	1945	2	2018	1677959444712.0	1732856647000	403057250480	2	WTP	99.83	84	89	91	91
3	Majelis Mahkamah Agung	1945	5	2018	1238916251222.0	8478236820000	842341874626	1657	WTP	97.29	80	83	94	94
4	Kepulauan Riau	1960	6	2018	1734025259948.0	4723254340000	41182688884	230	WTP	96.23	79	81	90	90
5	Kementerian Sosial	1960	7	2018	964861581687.0	2400743300000	233031276993	14	WTP	99.87	87	94	88	88
6	Kementerian Kesehatan	1945	10	2018	5275479470640.0	3252353200000	307524079381	123	WTP	99.88	80	85	76	76
7	Kementerian Luar Negeri	1945	11	2018	1633888484442.0	7845758840000	754756279222	145	WTP	99.99	89	77	91	91
8	Kementerian Dalam Negeri	1945	12	2018	5427321444038.0	113335805870.0	106824272635	454	WTP	99.49	79	85	93	93
9	Kementerian Hukum dan HAM	1945	13	2018	246297954548.0	3737916182000	324746995357	1167	WTP	99.85	73	82	96	96
10	Kementerian Energi dan Sumber Daya Mineral	1945	15	2018	9876294579487.0	2018782720000	399046808665	1103	WTP	99.96	84	84	90	90
11	Kementerian Pertanian	1945	18	2018	246820254276.0	2424851083000	218960283094	631	WTP	99.45	85	86	89	89
12	Kementerian Pendidikan dan Kebudayaan	1950	19	2018	5469712321216.0	2847623000000	262811030884	132	WTP	99.13	86	86	88	88
13	Kementerian Agama	1959	20	2018	1214248209154.0	6271484340000	59104747624	31	WTP	99.87	81	84	88	88
14	Kementerian Ketenagakerjaan	1945	23	2018	2417817484048.0	3342343300000	657574158748	407	WTP	99.93	83	88	90	90
15	Kementerian Perencanaan Pembangunan Nasional/Bappenas	1945	23	2018	147733342835.0	4093436672000	3941243563086	319	WTP	99.44	80	91	85	85
16	Kementerian Komunikasi dan Informatika	1945	24	2018	499991073086.0	1188477460000	5714651746677	418	WTP	99.85	82	85	90	90
17	Kementerian A/B/C	1946	25	2018	476118006031.0	131602992624000	9130789216267	4207	WTP	99.64	82	80	91	91
18	Kementerian Koperasi dan Usaha Kecil dan Menengah	1947	26	2018	439439395337.0	3994939620000	3754438642841	214	WTP	99.33	75	79	81	81
19	Kementerian Kelautan dan Perikanan	1945	27	2018	9879631233168.0	4833816480000	4234842875464	209	WTP	99.31	77	76	87	87
20	Kementerian Lingkungan Hidup dan Kehutanan	1978	29	2018	8171004101670.0	8000616670000	7180914725456	332	WTP	99.46	81	80	90	90
21	Kementerian Perhubungan	1959	32	2018	161571233184.0	7622623600000	309737084297	408	WTP	99.79	87	81	89	89
22	Kementerian Perindustrian	1945	33	2018	915582118724.0	1154822913300.0	102483484822	185	WTP	99.85	82	89	94	94
23	Kementerian Ketenagakerjaan	1978	34	2018	24995666839.0	2892357000000	23187738128	1	WTP	100.00	82	100	54	54
24	Kementerian Ketenagakerjaan	1960	40	2018	442523986640.0	4332325500000	438006406273	2	WTP	99.98	49	93	62	62
25	Kementerian Ketenagakerjaan	2014	36	2018	167795928987.0	3821033300000	26038316044	3	WTP	99.99	85	95	88	88
26	Kementerian Ketenagakerjaan	1959	40	2018	128438208200.0	2732463340000	423798821980	240	WTP	99.89	82	89	90	90
27	Kementerian Ketenagakerjaan	1960	41	2018	27202220047.0	9443383400000	85648184840	119	WTP	99.87	84	84	89	89
28	Kementerian Ketenagakerjaan	1978	47	2018	133482719447.0	5561782040000	5168250241	41	WTP	85.36	71	77	77	77
29	Kementerian Ketenagakerjaan	1960	48	2018	75274424818.0	3573846400000	3036242320	2	WTP	99.90	85	48	81	81
30	Kementerian Ketenagakerjaan	1960	50	2018	90546479882.0	5626282100000	562817279113	1	WTP	100.00	89	100	100	100
31	Kementerian Ketenagakerjaan	1972	51	2018	3218724484840.0	9482150000000	94279195416	1	WTP	100.00	89	100	91	91
32	Kementerian Ketenagakerjaan	1946	52	2018	10311444444.0	4462544000000	4066444444	1	WTP	100.00	89	89	100	100
33	Kementerian Ketenagakerjaan	1947	54	2018	308623882280.0	4778770300000	43488187486	314	WTP	99.85	87	92	94	94
34	Kementerian Ketenagakerjaan	1947	55	2018	163446818710.0	2095323400000	25213263990	14	WTP	99.88	87	79	81	81
35	Kementerian Ketenagakerjaan	1955	56	2018	6263468873712.0	9218117478000	788653030430	500	WTP	99.90	85	84	93	93
36	Kementerian Ketenagakerjaan	1950	57	2018	1584458299384.0	5484316380000	55954718142	37	WTP	99.99	89	82	77	77

Reset

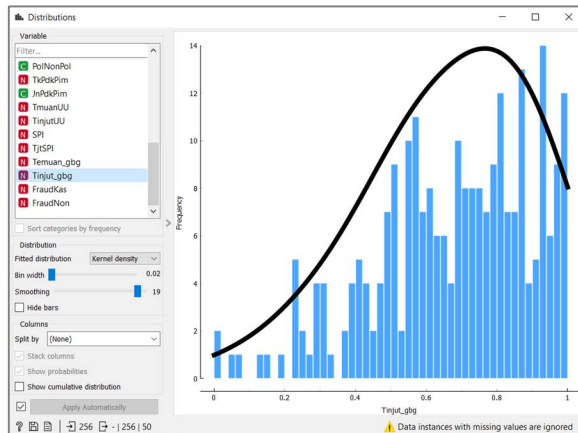
Apply

Browse documentation datasets


256

Exploratory Data

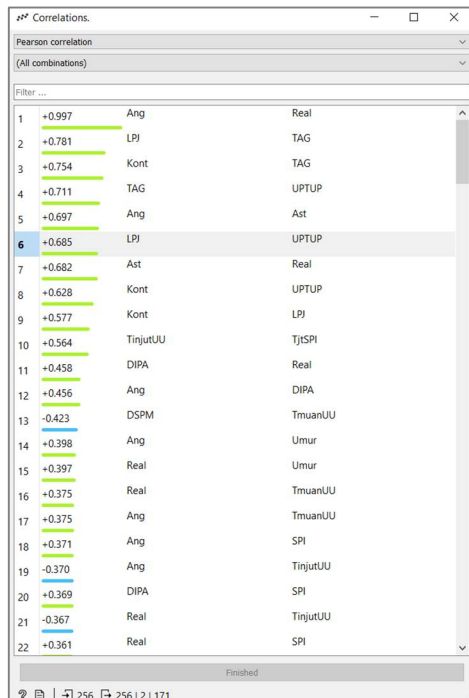
1. Skwenes Distribusi



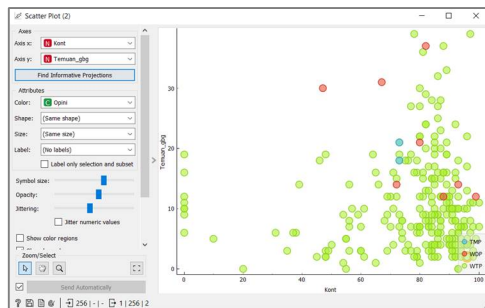
2. Feature Statistic



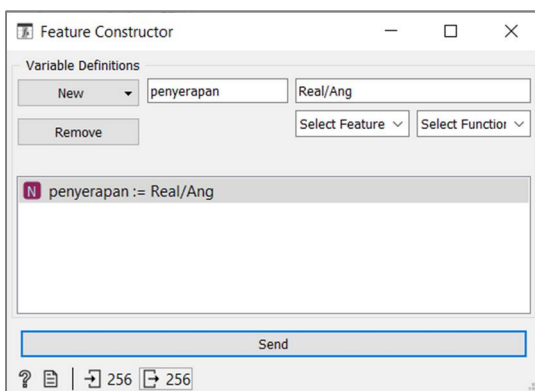
3. Correlation



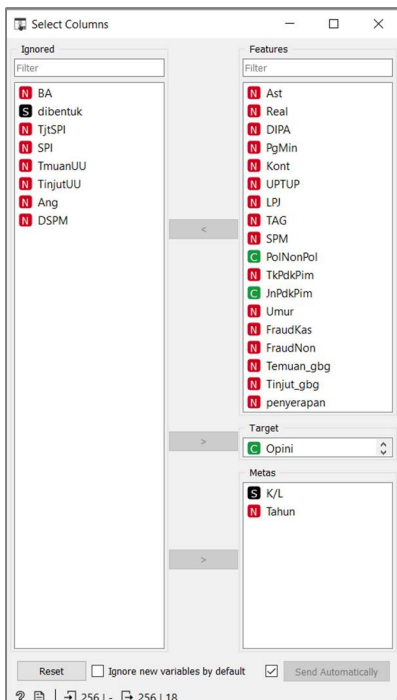
4. Scatter Plots



Feature Contractor



Select Collums



Impute Missing Value

Impute

Default Method

☐ Don't impute

☒ Average/Most frequent

☐ As a distinct value

☐ Fixed values; numeric variables: 0, time: 1970-01-01 07:00:00

☐ Model-based imputer (simple tree)

☐ Random values

☐ Remove instances with unknown values

Individual Attribute Settings

Filter...

1 Ast

2 Real

3 DIPA

4 PgMin

5 Kont

6 UPTUP

7 LPJ

8 TAG

9 SPM

10 PoiNonPol

☐ Default (above)

☐ Don't impute

☐ Average/Most frequent

☐ As a distinct value

☐ Model-based imputer (simple tree)

☐ Random values

☐ Remove instances with unknown values

☐ Fixed value

Restore All to Default

Apply Automatically

Data setelah perbaikan

Data Table (1)

256 instances (no missing data)
18 features
Target with 3 values
2 meta attributes

Variables

☒ Show variable labels (if present)
☒ Visualize numeric values
☒ Color by instance classes

Selection

☒ Select full rows

dataset_gpm2-Sheet1

dataset_gpm2-Sheet2

	Opini	KUL	Tahun	Ast	Real	DIPA	PgMin	Kont	UPTUP	LPJ	TAG	SPM	PoiNonPol
1	WTP	Majelis Permus...	2018	647879450705.0	809004298328	2	99.67	95	95	100.00	96.80	98.24	0
2	WTP	Dewan Perwakilan...	2018	1427559444172.0	4603672520480	2	99.83	84	99	91.67	81.59	97.75	0
3	WTP	Mahkamah Ag...	2018	1238316251722...	8423418714626	1657	97.29	80	83	94.29	94.19	95.93	0
4	WTP	Kekayaan Repu...	2018	1734922359169...	6118788586384	530	96.83	78	93	90.94	92.65	92.67	1
5	WTP	Kementerian Se...	2018	984686168167...	233033276993	14	99.87	87	94	88.10	95.69	98.44	0
6	WTP	Kementerian D...	2018	5275417947506.0	3075274973631	123	99.88	80	85	76.60	88.86	97.59	1
7	WTP	Kementerian Lu...	2018	163388684842...	7543768275922	145	99.99	89	77	91.67	96.78	97.74	0
8	WTP	Kementerian Pe...	2018	5437321464538...	1066804272435...	454	99.49	79	85	93.60	84.67	95.07	0
9	WTP	Kementerian H...	2018	2462931954289...	12641689503527	1167	99.85	73	82	94.00	93.56	96.43	1
10	WTP	Kementerian Ke...	2018	3876239457947...	2999046838665	1103	99.96	84	84	92.22	92.35	95.92	0
11	WTP	Kementerian Lu...	2018	2460620934216...	21836602837694	631	99.45	85	96	89.90	94.36	96.29	0
12	WTP	Kementerian Pe...	2018	5669172537216.0	2628110102894	132	99.13	86	86	88.46	96.30	97.37	1
13	WTP	Kementerian En...	2018	1232428050154...	5910847241624	31	99.87	81	94	86.62	90.17	98.60	0
14	WTP	Kementerian Pe...	2018	2411917648420...	45075741354758	607	99.93	83	88	92.02	94.98	96.40	0
15	WTP	Kementerian Ke...	2018	1471555450855...	2842435838896	319	99.44	80	91	85.39	92.52	96.33	0
16	WTP	Kementerian Lu...	2018	4999976735965...	57248657406677	418	99.85	82	85	90.74	94.28	96.87	0
17	WTP	Kementerian A...	2018	4703785008511...	59380999210267	6207	99.64	82	80	93.59	91.20	94.40	1
18	WTP	Kementerian Ke...	2018	439415995537.0	3754418642841	314	99.53	75	79	81.75	94.32	97.44	1
19	WTP	Kementerian So...	2018	5979931123161.0	41234142871044	209	99.51	77	76	87.26	92.81	91.22	1
20	WTP	Kementerian Lu...	2018	8171004101670...	7180934725456	332	99.46	81	80	90.89	95.31	96.65	1
21	WTP	Kementerian Lu...	2018	1061575233186...	6097370854297	408	99.70	87	83	89.67	95.22	96.73	0
22	WTP	Kementerian Pe...	2018	9155805116724...	1024836484522...	1165	99.85	82	89	94.09	96.58	97.24	0
23	WTP	Kementerian Ko...	2018	7049066839.0	231677581328	1	100.00	82	100	58.33	96.77	98.89	1
24	WTP	Kementerian Ko...	2018	44353996666.0	438090945673	2	99.98	49	93	62.50	76.63	99.14	0
25	WTP	Kementerian Ko...	2018	167070550997.0	26020176044	3	99.99	85	85	88.89	99.79	98.96	1
26	WTP	Kementerian Ba...	2018	3108183996508.0	353293240084	47	98.80	56	89	81.10	77.57	92.57	0
27	WTP	Kementerian Ba...	2018	569150117137.0	227448357037	1	99.91	81	95	91.67	95.36	96.78	0
28	WTP	Kementerian RI...	2018	1264382080200...	43237988215900	240	99.89	82	89	90.66	93.00	96.02	0
29	WTP	Kementerian Ko...	2018	272020200475.0	858493948940	119	99.97	84	84	80.85	95.32	94.65	1
30	WTP	Kementerian Lu...	2018	138483719447.0	516882550241	41	85.36	71	77	77.89	87.93	97.53	0
31	WTP	Kementerian Pe...	2018	73275402613.0	303962692520	2	99.90	85	48	87.50	85.80	95.51	1
32	WTP	Badan Interjel...	2018	1058464378982...	5628574279113	1	100.00	89	100	100.00	97.49	95.26	0
33	WTP	BADAN SIBER ...	2018	3238720408649.0	942397195416	1	100.00	99	100	91.67	100.00	99.01	0
34	WTP	Dewan Ketahan...	2018	126115494261.0	40666844586	1	100.00	100	89	100.00	100.00	95.99	0
35	WTP	Badan Pusat Sta...	2018	3080320882390...	4584881837486	514	99.95	87	92	94.92	93.43	97.40	0
36	WTP	Kementerian Pe...	2018	1463848917293.0	252132805990	34	99.88	78	79	81.31	76.39	97.52	0
37	WTP	Kementerian A...	2018	6263465897312.0	7886533063340	500	99.90	85	84	93.51	94.64	96.91	0

Restore Original Order

Send Automatically

Model Evaluation

Test and Score Random Sampling

Sampling

☐ Cross validation

Number of folds: 10

☒ Stratified

☐ Cross validation by feature

☒ Random sampling

Repeat train/test: 20

Training set size: 70 %

☒ Stratified

☐ Leave one out

☐ Test on train data

☐ Test on test data

Target Class

(Average over classes)

Evaluation Results

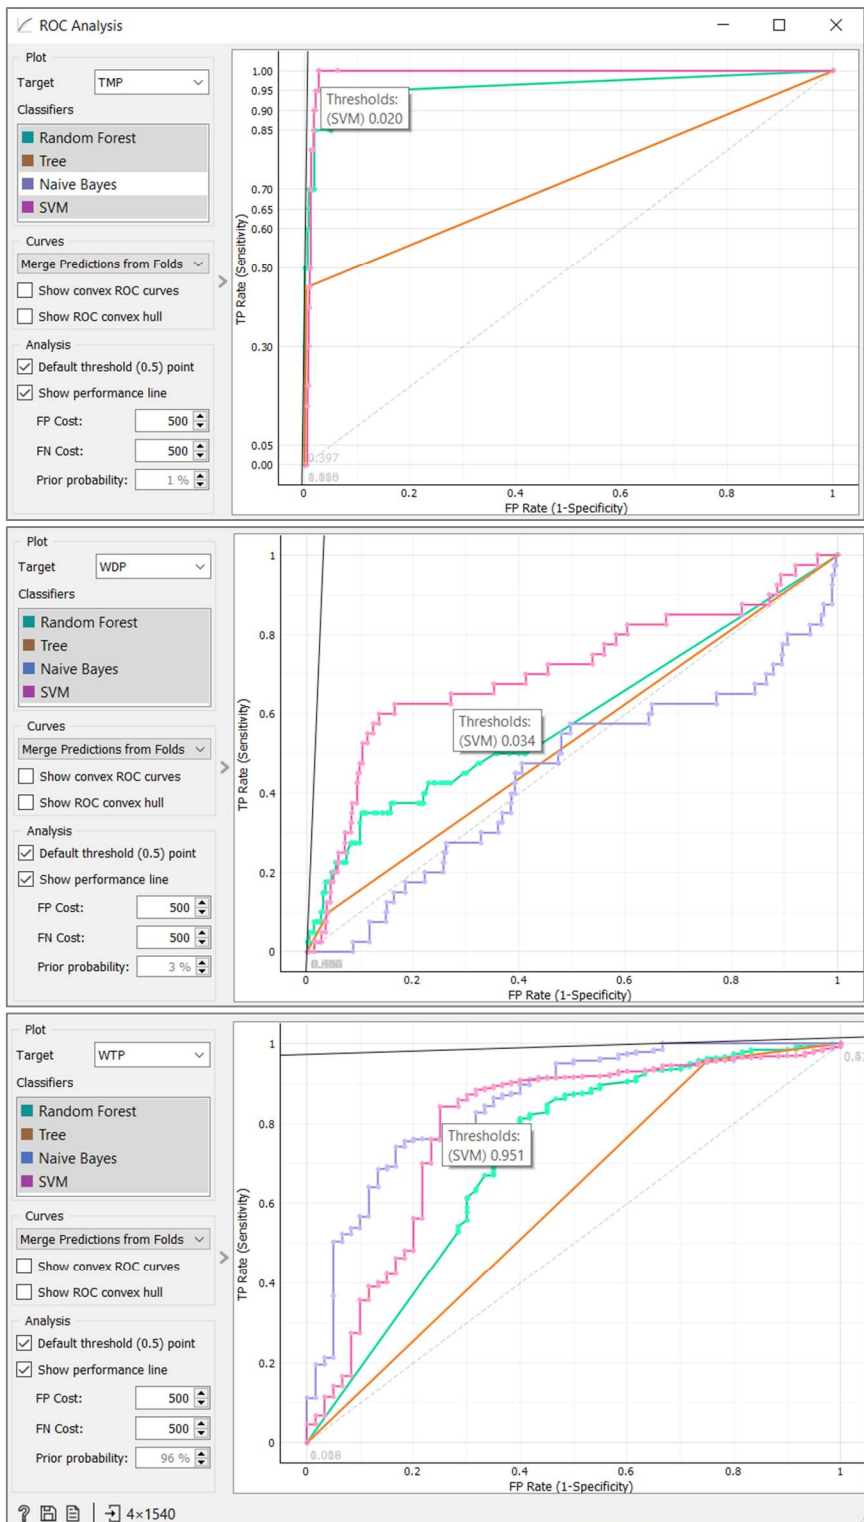
Model	AUC	CA	F1	Precision	Recall
Tree	0.599	0.927	0.934	0.941	0.927
SVM	0.823	0.961	0.942	0.924	0.961
Random Forest	0.741	0.961	0.943	0.937	0.961
Naive Bayes	0.741	0.013	0.000	0.000	0.013

Model Comparison by AUC

	Tree	SVM	Random ...	Naive Ba...
Tree				
SVM				
Random Forest				
Naive Bayes				

Table shows probabilities that the score for the model in the row is higher than that of the model in the column. Small numbers show the probability that the difference is negligible.

ROC Analysis



Output

Output

1540 instances (no missing data)

18 features

Target with 3 values

19 meta-attributes

Variables

☐ Show variable labels (if present)

☒ Visualize numeric values

☐ Color by instance classes

Selection

☒ Select full rows

Restore Original Order

☒ Send Automatically

	Opis	URL	Tahun	Random Forest	Tree	Naive Bayes	SVM	Random Forest (TMP)	Random Forest (WOF)	Random Forest (WTF)	Tree (TMP)	Tree (WOF)	Tree (WTF)
1	WTP	Kementerian Pe...	2018 WTP	WTP	TMP	TMP	WTP	0	0	1	0	0	0
2	WTP	Kementerian Pe...	2020 WTP	WTP	TMP	TMP	WTP	0	0	1	0	0	0
3	WTP	Badan Informas...	2018 WTP	WTP	TMP	TMP	WTP	0	0	1	0	0	0
4	WTP	Kementerian H...	2019 WTP	WTP	TMP	TMP	WTP	0	0.144444	0.855556	0	0	0
5	WTP	Kementerian Pa...	2019 WTP	WTP	TMP	WTP	0	0	0	1	0	0	0
6	WTP	Pusat Pelaporan...	2018 WTP	WTP	TMP	WTP	0	0.0285714	0.0952381	0.961905	0	0	0
7	WTP	Badan Standar...	2019 WTP	WTP	TMP	WTP	0	0	0	1	0	0	0
8	WTP	Badan Pengawa...	2018 WTP	WTP	TMP	WTP	0	0	0	1	0	0	0
9	WTP	Kementerian Ke...	2019 WTP	WTP	TMP	WTP	0	0.222222	0.777778	0	0	0	0
10	WTP	Kementerian Ba...	2020 WTP	WTP	TMP	WTP	0	0	0	1	0	0	0
11	WTP	Kementerian H...	2020 WTP	WTP	WDP	WTP	0	0.0666667	0.933333	0	0	0	0
12	WTP	Kementerian Pe...	2018 WTP	WDP	WTP	WTP	0	0.133333	0.866667	0	0	0	1
13	WTP	Badan Informas...	2019 WTP	TMP	TMP	WTP	0	0	0	1	0	0	0
14	WTP	Kementerian Ri...	2019 WTP	WTP	TMP	WTP	0	0	0	1	0	0	0
15	WTP	Sekretariat Kabi...	2020 WTP	WTP	TMP	WTP	0	0	0	1	0	0	0
16	WTP	Badan Tenaga ...	2020 WTP	WTP	TMP	WTP	0	0	0	1	0	0	0
17	WTP	Kementerian Pe...	2018 WTP	WDP	WTP	WTP	0	0.0666667	0.933333	0	0	0	1
18	WTP	Kementerian Ke...	2018 WTP	WTP	TMP	WTP	0	0	0	1	0	0	0
19	WTP	Badan Informas...	2018 WTP	WTP	TMP	WTP	0.111111	0.0333333	0.855556	0	0	0	0
20	WTP	Kementerian Pe...	2020 WTP	WTP	TMP	WTP	0	0	0	1	0	0	0
21	WTP	Kepulauan Repu...	2020 WTP	WTP	TMP	WTP	0	0.211111	0.788889	0	0	0	0
22	WTP	Majelis Permusy...	2020 WTP	WTP	TMP	WTP	0	0	0	1	0	0	0
23	WTP	Kementerian Ko...	2018 WTP	WTP	TMP	WTP	0	0	0	1	0	0	0
24	WTP	Ombudsman Re...	2020 WTP	WTP	TMP	WTP	0	0	0	1	0	0	0
25	WTP	Badan Tenaga ...	2019 WTP	WTP	TMP	WTP	0	0	0	1	0	0	0
26	WTP	Badan Kepegaa...	2018 WTP	WTP	TMP	WTP	0	0	0	1	0	0	0
27	WTP	Badan Informas...	2020 WTP	WTP	TMP	WTP	0	0	0	1	0	0	0
28	WTP	Badan Tenaga ...	2018 WTP	WTP	TMP	TMP	WTP	0	0.0666667	0.933333	0	0	0
29	WTP	Kementerian Ko...	2019 WTP	WTP	TMP	TMP	WTP	0	0	1	0	0	0
30	WTP	Kementerian Pe...	2019 WTP	WTP	TMP	WTP	0	0	0	1	0	0	0
31	WDP	BADAN INFORMATIKA	2018 WTP	WTP	TMP	WTP	0	0	0	1	0	0	0
32	WTP	Kementerian En...	2020 WTP	WTP	TMP	WTP	0	0	0	1	0	0	0
33	WTP	Kementerian Ko...	2020 WTP	WTP	TMP	WTP	0	0	0	1	0	0	0
34	WTP	Perpustakaan n...	2020 WTP	WTP	TMP	WTP	0	0.0452381	0.0952381	0.945238	0	0	0
35	WTP	Badan Pengaki...	2020 WTP	WTP	TMP	WTP	0	0	0	1	0	0	0
36	WTP	Ombudsman Re...	2019 WTP	WTP	TMP	WTP	0	0	0	1	0	0	0
37	WTP	Badan Nasional...	2018 WTP	WTP	TMP	WTP	0	0	0	1	0	0	0
38	WTP	Komissi Peminta...	2020 WTP	WTP	TMP	TMP	WTP	0.0285714	0.303968	0.66746	0	0	0

Variabel berpengaruh

1. Decrease Gini

	#	Gini
N FraudKas		0.065
N Tem...gbg		0.035
N Tinjut_gbg		0.025
N UPTUP		0.018
N Real		0.016
N LPJ		0.015
N Ast		0.014
N Umur		0.014
N FraudNon		0.013
N Kont		0.010
N PqMin		0.009
N DIPa		0.009
N TkPdkPim		0.008
N TAG		0.006
C JnPdkPim	2	0.005
N SPM		0.005
N Pen...pan		0.004
C PolNonPol	2	0.001

2. FreViz



Save Pickled Models

