

ANALISIS KEMAMPUAN MEMBAYAR KEMBALI PINJAMAN OLEH PEMERINTAH DAERAH DENGAN METODE NAIVE BAYES, GRADIENT BOOSTING, SUPPORT VECTOR MACHINE DAN NEURAL NETWORK SEBAGAI EARLY WARNING SYSTEM

*Adhitya Ahmad, Hasnadya Fitri Nugraheni, Reynaldi Wisnu Werdhana, Hany Sukma
Setyaningtyas, Ivanderaihan Subagiyono*

Direktorat Sistem Manajemen Investasi

Abstract

A Local Government's ability to repay debts is dissimilar to that of a for-profit legal entity, as Local Governments strive to manage public needs and interests. Accordingly, the purpose of this research is to develop an Early Warning System (EWS) in order to predict the ability to repay debts submitted by Local Governments, to prevent default risk. This research uses data samples from 34 provinces in Indonesia during the 2016 through 2020 period, with a total of 12 variables obtained from the Balance Sheet, Budget Realization Report, and Gross Regional Domestic Product data. K-Means Cluster was carried out in the beginning to determine the optimal number of clusters, resulting in 2 clusters with a silhouette score of 0,584. Classification analysis was subsequently done using the Naive Bayes Classifier, Gradient Boosting Machine, Support Vector Machine, and Neural Network methods. The most accurate resulting classification was attained by using the Neural Network Cross Validation 5 folds method, with an AUC of 0,997 and F1 score of 0,988.

Abstrak

Kemampuan membayar kembali kewajiban hutang Pemerintah Daerah tidak sama dengan Badan Usaha yang tujuan pendiriannya untuk mendapat profit, karena tujuan yang dikelola oleh Pemerintah Daerah lebih banyak untuk kepentingan publik. Oleh karena itu, tujuan penelitian ini adalah mencari solusi peringatan dini (*Early Warning System*) dalam rangka memprediksi kemampuan membayar kembali pinjaman yang diajukan Pemerintah Daerah untuk menghindari risiko gagal bayar. Penelitian ini menggunakan data sample dari 34 Provinsi di Indonesia selama kurun waktu 2016 sampai dengan 2020 dengan total 12 variabel yang didapat dari Neraca, LRA dan data PDRB. *K-Means Cluster* dilakukan pada tahap awal untuk menentukan jumlah *cluster* yang optimal, dimana didapatkan 2 *cluster* dengan *silhouette score* sebesar 0,584. Selanjutnya dilakukan analisis klasifikasi menggunakan metode *Naive Bayes Classifier*, *Gradient Boosting Machine*, *Support Vector Machine* dan *Neural Network*. Hasil prediksi klasifikasi terbaik

menggunakan metode *Neural Network Cross Validation 5 folds*, yaitu AUC sebesar 0,997 dan F1 Score 0,988.

Keywords: *Cluster, Neural Network, AUC*

JEL Classification: *Financial Economics*

1. PENDAHULUAN

1.1 Latar Belakang

Sesuai dengan Undang-Undang Nomor 23 Tahun 2014 tentang Pemerintah Daerah, penyelenggaraan pemerintahan daerah diarahkan untuk mempercepat terwujudnya kesejahteraan masyarakat melalui peningkatan pelayanan, pemberdayaan, dan peran serta masyarakat, serta peningkatan daya saing daerah. Pelaksanaannya dengan memperhatikan prinsip demokrasi, pemerataan, keadilan, dan kekhasan suatu daerah dalam sistem Negara Kesatuan Republik Indonesia.

Pemerintah daerah menggunakan APBD sebagai alat utama dalam mewujudkan tujuan tersebut. Keterbatasan dana dalam APBD dan *mandatory spending* yang semakin meningkat menjadi tantangan pemerintah daerah untuk mengakselerasi pembangunan di daerah. Permasalahan Fiskal Gap APBD antara keterbatasan dana APBD dan *mandatory spending* yang semakin meningkat membuat pemerintah daerah membutuhkan *alternatif source of fund* pembiayaan.

Pemerintah daerah sesuai dengan Peraturan Pemerintah Nomor 30 Tahun 2011 memiliki payung hukum untuk melakukan pinjaman. Terdapat beberapa sumber pembiayaan yang dapat digunakan oleh pemerintah daerah untuk menutupi kekurangan likuiditasnya, salah satunya melalui penerusan pinjaman. *Subsidiary Loan Agreement* (SLA)/ Penerusan Pinjaman Luar Negeri (PPLN) merupakan skema pinjaman lunak jangka panjang yang dananya bersumber dari luar negeri atau lembaga internasional yang

pelaksanaannya mengacu pada Peraturan Pemerintah nomor 10 tahun 2011. Selain itu terdapat juga Penerusan Pinjaman Dalam Negeri mengacu pada Peraturan Pemerintah No 54 Tahun 2008.

Selama ini penerusan pinjaman yang telah diberikan pemerintah menggunakan skema PPLN. Dalam menyetujui permohonan pinjaman PPLN pemerintah pusat dalam hal ini Direktorat Sistem Manajemen Investasi (Dit. SMI) wajib mengedepankan prinsip kehati-hatian (*prudential principle*) atau yang dikenal dengan Prinsip 5C (*Character, Capacity, Capital, Collateral, dan Condition of Economy*), yang dimana Dit. SMI harus melakukan pemeriksaan secara menyeluruh terhadap calon debitur dalam hal kesanggupan debitur membayar dan memenuhi prestasi atau utangnya dengan cara melihat dan menilai watak, kemampuan membayar kembali, modal, agunan dan prospek/kondisi usaha.

Tujuan penelitian ini adalah mencari solusi peringatan dini (*Early Warning System*) terhadap isu kemampuan membayar kembali pinjaman yang diajukan Pemerintah Daerah. Tidak seperti badan usaha yang tujuan pendiriannya untuk mendapat profit setinggi-tingginya, Pemerintah Daerah hadir untuk mensejahterakan masyarakatnya, mengakselerasi pemerataan pembangunan daerah dan memastikan standar kehidupan yang layak telah merata pada setiap lapisan masyarakat melalui pemenuhan *mandatory spending*. Oleh karena itu tingkat profitabilitas untuk membayar kembali kewajiban utang pada Pemda lebih rendah karena kepentingannya lebih banyak dibanding badan usaha.

Early Warning System yang efektif dapat membantu pemerintah menilai risiko utang pemerintah daerah dan mengambil tindakan tepat waktu untuk mencegah risiko gagal bayar pada pemberian SLA. Penelitian sejenis sebelumnya pernah dilakukan oleh Fuertes dan Kalotychou (2006), penelitian tersebut membangun model *Early Warning System* (EWS) untuk menganalisis risiko krisis hutang negara menggunakan variabel dependen biner. Penelitian lain juga pernah dilakukan oleh Kamra, K (2013) menggunakan data panel dari 37 emerging market country selama tahun 1990 sampai dengan 2010 dengan menggunakan model Logistic Regression dan Bayesian Model Averaging. Selanjutnya Antulov-Fantulin, dkk (2021) juga melakukan prediksi kebangkrutan pemerintah daerah menggunakan pendekatan *machine learning*. Shi, dkk (2010) menggunakan pendekatan *Neural Network* untuk membangun *Early Warning System* untuk risiko finansial pemerintah. Yinqiu Tao (2013) menggunakan pendekatan *Principal Component Analysis* dan *Multivariate Discriminant Analysis* dalam menilai risiko gagal bayar pemerintah daerah di China.

Dalam penelitian ini penulis melakukan analisis terhadap kemampuan membayar kembali khususnya debitur Pemerintah Provinsi menggunakan data laporan realisasi anggaran dan neraca 5 tahun sebelumnya dengan metode analisis *Support Vector Machine*, *Naive Bayes*, *Gradient Boosting* dan *Neural Network* sebagai untuk membangun model *Early Warning System* terhadap risiko membayar kembali pinjaman Pemerintah Provinsi di Indonesia

dengan menggunakan data seluruh Provinsi di Indonesia selama tahun 2016 sampai dengan 2020.

Analisis yang dilakukan pada penelitian ini mencoba menjawab beberapa pertanyaan diantaranya: bagaimana karakteristik dari data yang digunakan? Berapa jumlah kluster optimal dari variabel-variabel yang digunakan? Metode apa yang menghasilkan area *under curve* paling optimal? Bagaimana mendapatkan model terbaik untuk memprediksi risiko Pemerintah Daerah dalam membayar kembali pinjaman?

2. TINJAUAN LITERATUR

2.1 K-Means Cluster

Algoritma *K-Means* merupakan algoritma klasterisasi yang mengelompokkan data berdasarkan titik pusat kluster (*centroid*) terdekat dengan data. Data dikelompokkan dengan memaksimalkan kemiripan data dalam satu kluster dan meminimalkan kemiripan data antar kluster. Parameter kemiripan yang digunakan dalam kluster adalah fungsi jarak. Kemiripan data dimaksimalkan dari jarak terpendek antara data terhadap titik *centroid*.

Tahapan pada proses klasterisasi data dengan algoritma *K-Means* diawali dengan membentuk titik awal *centroid* C_j . Pembentukan titik awal *centroid* dibangkitkan secara acak umumnya. Jumlah *centroid* C_j yang dibangkitkan sesuai dengan jumlah kluster yang ditentukan. Setelah, *centroid* terbentuk, selanjutnya menghitung jarak tiap data X_i dengan *centroid* ke- j sampai k , dinotasikan dengan $d(X_i, C_j)$. Terdapat beberapa ukuran jarak yang digunakan sebagai ukuran kemiripan suatu *instance* data, salah satunya adalah jarak *Euclid*.

Perhitungan jarak *Euclidean* seperti pada Persamaan 4.

$$d(X_i, C_j) = \sqrt{\sum_{i=1}^N (X_i - C_j)^2} \quad (1)$$

Jika $d(X_i, C_j)$ semakin kecil maka kesamaan antara dua unit pengamatan semakin dekat. Syarat dari Penggunaan jarak *Euclid* adalah semua fitur dalam dataset yang tidak saling berkorelasi. Apabila terdapat fitur yang berkorelasi maka menggunakan konsep jarak Mahalanobis, (Duran dan Odell, 1974).

Kelanjutan dari jarak tersebut dicari yang terdekat sehingga data akan mengelompok berdasarkan *centroid* yang paling dekat (Agusta, 2007). Tahap berikutnya, dilakukan update titik *centroid* dengan menghitung rata-rata jarak seluruh data terhadap *centroid*. Kemudian, akan kembali lagi ke proses awal. Iterasi ini akan terus diulang hingga *centroid* yang konstan didapatkan, dimana titik *centroid* sudah tidak berubah lagi. Atau Iterasi dihentikan berdasarkan jumlah iterasi maksimal yang ditentukan.

2.2 Naive Bayes Classifier

Naive Bayes Classifier merupakan sebuah metode pengklasifikasi probabilitas sederhana yang menerapkan Teorema Bayes dengan asumsi ketidaktergantungan yang tinggi. Konsep dasar dari metode ini adalah teorema Bayes, dimana didalam statsitika teorema ini banyak digunakan untuk menghitung peluang. Bila diketahui A_1, A_2, \dots, A_n adalah sebuah kejadian yang independen dalam ruang sampel Ω , sehingga $\sum_{i=1}^n A_i = \Omega$. B merupakan sebuah kejadian *random* dan kejadian $A_1 \cap B, A_2 \cap B, \dots, A_n \cap B$ merupakan partisi dalam B . Bila diberikan $\{A_1, A_2, \dots, A_n\}$ adalah atribut yang digunakan untuk menentukan

kelas C , dengan menggunakan teorema Bayes maka perhitungan posterior probability untuk setiap kelas C adalah sebagai berikut (Gorunescu, 2011).

$$P(A_1, A_2, \dots, A_n) = \frac{P(A_1, A_2, \dots, A_n | C_j) P(C_j)}{\sum_{i=1}^n P(A_1, A_2, \dots, A_n)}$$

Apabila kelas tersebut memaksimalkan nilai $P(C_j | A_1, A_2, \dots, A_n)$ atau memaksimalkan nilai $P(A_1, A_2, \dots, A_n | C_j)$, maka kelas tersebut yang dipilih. Berdasarkan persamaan diatas, diperlukan perhitungan $P(A_1, A_2, \dots, A_n | C_j)$. Setiap atribut diasumsikan independen untuk setiap kelas C .

$$P(A_i | C_j) = \frac{1}{\sigma_{ij} \sqrt{2\pi}} \exp \left(-\frac{(A_i - \mu_{ij})^2}{n} \right) \quad (2)$$

Dugaan peluang $P(A_i | C_j)$ dapat dihitung untuk setiap atribut A_i dan kelas C_j , sehingga data baru dapat diklasifikasikan kedalam kelas C_k jika peluang yang didapat merupakan yang terbesar diantara peluang lainnya.

2.3 Gradient Boosting Machine

Gradient Boosting Machine (GBM) merupakan teknik *machine learning* yang menggunakan metode kontinyu untuk membentuk *decision tree*. Algoritma dari GBM adalah sebagai berikut:

Misalkan $A = (x_1, x_2, \dots, x_n)$ digunakan sebagai variabel bebas dan $B = \{y_i\}$ sebagai variabel terikat, dengan $i = 1, 2, \dots, n$. Pada sebuah data set, variabel dalam A perlu dipetakan kepada B melalui fungsi pemetaan $f^*(x)$. Selisih antara fungsi pemetaan dengan fungsi nyata dinyatakan dengan fungsi rugi $L(y, f(x))$. Model prediksi meminimalisir fungsi rugi $L(y, f(x))$ dengan cara menjalankan fungsi pemetaan $f^*(x)$ persamaan (3)

$$f^*(x) = \arg \min \sum_{i=1}^n L(y_i, \delta) \quad (3)$$

Berdasarkan GBM, arah L menurun sesuai dengan arah gradien, sebab L mengalami perubahan paling signifikan pada arah tersebut. Oleh karena itu, nilai gradien negatif dari L akan berkisaran pada residu, sebagaimana dapat ditentukan dengan persamaan (4)

$$r_{im} = - \left[\frac{\partial L(y_i, f(x_i))}{\partial f(x_i)} \right]_{f^*(x) - f_{m-1}^*(x)} \quad (4)$$

Pseudo-residual turunan dari persamaan diatas dipasangkan dengan dasar pengklasifikasian $g_m(x)$ yang memuat berbagai parameter dan dilatih dengan *training set* $\{(x_i, r_{im})\}_{i=1}^n$. Kemudian, δ_m dapat ditentukan dari pengoptimalan sebagai berikut:

Koefisien sisa y_m diperoleh dari persamaan (5)

$$y_m = \arg \min \sum_{i=1}^n L(y_i, f_{m-1}^*(x_i) + \delta g_m(x_i)) \quad (5)$$

Setelah iterasi $m = 1, 2, \dots, M$, fungsi prediksi teroptimalkan dapat diperoleh, sebagai berikut (6)

$$f_m^*(x) = f_{m-1}^*(x) + \delta_m g_m(x) \quad (6)$$

Sehingga pada kesimpulannya, GBM secara umum memuat parameter sebagai berikut: learning rate, tree depth, dan jumlah iterasi.

2.4 Support Vector Machine

Support Vector Machine (SMV) adalah learning machine yang digunakan untuk menemukan *hyperplane* paling baik dalam pemisahan dua kelas dengan jarak maksimal. SMV dipelopori oleh Vapnik pada 1992. Tahap pertama SMV adalah memetakan sampel secara non linier kemudian memaksimalkan fungsi klasifikasi dengan persamaan (1). Demi memperoleh *hyperplane* terbaik, persamaan (2) digunakan untuk mencari

pembatas diantara dua kelas. Penggabungan persamaan (1) dan persamaan (2) menjadi persamaan (3) kemudian dimasukkan *Gaussian Radial Basis Function* (RBF) menjadi persamaan (4).

$$\min_{\omega, b, \xi} \left(\frac{1}{2} \omega^T \omega + C \sum_{i=1}^n \xi_i \right) \quad (7)$$

$$\gamma_i (\omega^T \varphi(x_i) + b) \geq 1 - \xi_i$$


$$\text{sgn}(\omega^T \varphi(x) + b) = \text{sgn} \left[\sum_{i=1}^n y_i a_i K(x_i, x) + b \right]$$

Pada persamaan tersebut, ω dan b adalah *hyperplane* yang menyatakan posisi optimal pembatas kedua kelas, serta γ dan C merupakan parameter yang perlu dioptimalisasi. Keterangan lainnya dalam persamaan adalah sebagai berikut: x_i berarti input; y_i melambangkan vektor bobot output yang diharapkan; C diartikan sebagai parameter penalti dan $C \in (0, +\infty)$; ξ_i sebagai variabel *slack* dan $\xi_i \geq 0, i=1, 2, \dots$; b memiliki arti vektor bias; $K(x_i, x)$ adalah fungsi *Gaussian Radial Basis Function*; dan a_i merupakan *Lagrange multiplier*.

2.5 Neural Network


Neural Network atau *Artificial Neural Network* (ANN) adalah model prediktif yang mengadopsi cara kerja otak manusia atau disebut sebagai *supervised learning*. Model *Neural Network* dikembangkan pertama kali oleh Warren McCulloch dan Walter Pitts pada 1943. Sistem syaraf pada otak manusia terdiri atas dendrit sebagai penerima input, akson sebagai pengirim output ke jaringan lain, sinapsis sebagai penghubung antar syaraf. Suatu unit pemrosesan dalam *neural network* terdapat komponen lapisan input (*input-layer*), satu atau lebih lapisan tersembunyi (*hidden-layer*), dan lapisan output (*output-layer*). Setiap unit atau

mengandung kekuatan koneksi tertentu atau bobot (*weight*).



Gambar 2.1. Input-Output Layer Neural Network

Input yang diberikan ke dalam *neural network* memiliki bobot atau *weight* yang berbeda-beda. Bobot pada input yang disimbolkan dengan lambang sigma (Σ) akan diproses dalam fungsi rambatan atau *summing function*. Hasil dari *summing function* kemudian akan diproses dalam fungsi aktivasi atau *activation function*. *Activation function* akan membandingkan bobot dengan nilai ambang atau *threshold* tertentu. Jika bobot melebihi nilai ambang, aktivasi neuron dibatalkan. Neuron akan diaktifkan jika bobot input di bawah nilai ambang.




Gambar 2.2. Pembobotan Neural Network

Neural network akan belajar dengan melakukan prediksi bobot tersebut secara berulang-ulang dan menghasilkan penyesuaian bobot setiap ada prediksi yang salah sehingga meningkatkan akurasi prediksi dari *neural network* tersebut. Setelah pembelajaran selesai, sebuah *neural network* dapat memproyeksi

kemungkinan yang terjadi masa depan berdasarkan data yang diinput.

2.6 Kurva *Receiving Operating Characteristic (ROC)*

Kurva ROC digunakan untuk menentukan model dan metode terbaik dengan menggambarkan hubungan sensitivitas dan spesifisitas untuk mengukur dan mengevaluasi kinerja klasifikasi (Erke & Pattynama, 1998). Sensitivitas (true positive rate) diplot dalam fungsi 1-spesifisitas (*false positive rate*) pada titik cut off yang beragam. Tiap titik pada kurva ROC menggambarkan pasangan dari sensitivitas dan spesifisitas. Semakin dekatnya plot ROC dengan sudut kiri atas, akan menggambarkan semakin tingginya akurasi dari keseluruhan tes (Zweig & Campbell, 1993).



Gambar 2.3. Kurva ROC

Perhitungan kinerja klasifikasi dilakukan dengan menghitung luas daerah dibawah kurva ROC atau *Area Under the ROC Curve (AUC)*. Nilai AUC berada diantara 0 dan 1, dengan nilai 1 menandakan model 100% akurat dan nilai 0 menandakan 100% tidak akurat.

Misalkan Y merupakan variabel respon biner, yaitu 0 dan 1. Apabila *cut off* c adalah positif bila $Y \geq c$ dan negatif

bila $Y \leq c$. Nilai *cut off* c dihitung dengan persamaan (9)

$$\begin{aligned} c_1 &= kk - 1 \\ c_2 &= \frac{kk + kb}{2} \\ c_3 &= kb + 1 \end{aligned} \quad (8)$$

Dengan kk adalah kelas terkecil (0) dan kb adalah kelas terbesar (1) pada *variable respon*. Perhitungan sensitivitas (TP) dan 1-spesifisitas (FP) untuk random cutoff c didapatkan dengan persamaan (9)

$$\begin{aligned} TP(c) &= \frac{s_1(c)}{n_1} \\ FP(c) &= \frac{s_0(c)}{n_0} \end{aligned} \quad (9)$$

Estimasi AUC dengan metode non parametrik menggunakan *trapezoidal rule* dengan persamaan (10)

$$AUC = \frac{1}{n_1 n_0} \sum_{i=1}^{n_1} \sum_{j=1}^{n_0} \varphi(Y_{i1}, Y_{j0}) \quad (10)$$

$$\varphi(Y_{i1}, Y_{j0}) = \begin{cases} 1, & Y_{i1} > Y_{j0} \\ \frac{1}{2}, & Y_{i1} = Y_{j0} \\ 0, & Y_{i1} < Y_{j0} \end{cases} \quad (11)$$

Y_{i1} dan Y_{j0} merupakan gen untuk kelas positif dan negatif. Kategori berdasarkan nilai AUC dapat disajikan dalam tabel berikut.

Tabel 2.1 Kategori Pengklasifikasian Model berdasarkan Nilai AUC

Nilai AUC	Klasifikasi Model
0,90-1,00	Excelent
0,80-0,90	Good
0,70-0,80	Fair
0,60-0,70	Poor
0,50-0,60	Fail

Sumber : Bekkar, dkk., (2013)

3. METODOLOGI PENELITIAN

3.1 Sumber Data

Penelitian ini menggunakan data sekunder yang berasal dari LRA dan

Neraca pada laporan keuangan 34 Pemerintah Provinsi di Indonesia dalam kurun waktu 5 tahun (2016 sampai dengan 2020). Penelitian ini menggunakan metode *cluster k-means* beberapa pendekatan kuantitatif untuk model klasifikasi.

3.2 Variabel Penelitian

Variabel yang digunakan dalam penelitian ini terdiri dari 1 variabel respon (Y) dan 12 variabel prediktor. Berikut merupakan struktur data yang akan digunakan dalam penelitian ini.

Tabel 3.1 Struktur Data Penelitian Variabel

No	X1	X2	L	X12
1	$X_{1,1}$	$X_{2,1}$	L	$X_{12,1}$
2	$X_{1,2}$	$X_{2,2}$	L	$X_{12,2}$
3	$X_{1,3}$	$X_{2,3}$	L	$X_{12,3}$
...	O	...
170	$X_{1,170}$	$X_{2,170}$	L	$X_{12,170}$

Berikut ini penjelasan untuk variabel yang digunakan dalam penelitian ini:

Risk chain	Early warning indicators	Measurement
Debt Status	Dependence Degree of Debt	Current new debt dibagi (Current fiscal expenditure+ Debt principal repayment and interest in the current year)
	X1	
	Debt Ratio	Debt principal repayment and interest in the current year dibagi Current GDP
	X2	
	New Debt Ratio ^a	Current new debt dibagi Current fiscal revenue increment
	X3	
Debt Usage	The Ratio of GDP Growth to Debt Growth	Current GDP growth dibagi Current debt balance growth
	X4	
	Cost of Debt	Interest in the current year dibagi Debt balance in the previous year +0,5x Current new debt
	X5	
Debt Repayment	Debt Servicing Ratio	Debt principal repayment and interest in the current year dibagi Current fiscal revenue
	X6	
	Debt Burden Ratio	Current debt balance dibagi Current fiscal revenue
	X7	
Economic	Asset-liability Ratio	Current debt balance dibagi Current asset balance
	X8	
Economic	GDP Growth	Current GDP—GDP in the previous year

Strength	X9	dibagi GDP in the previous year
	Deficit Ratio	Current fiscal deficit dibagi Current GDP
	X10	
	Change of Fiscal Revenue and Expenditure ^c	Current fiscal revenue growth dibagi Current fiscal expenditure growth
Ketertagungan Fiskal	X11	
	X12	TKDD dibagi Total Pendapatan

3.3 Langkah Analisis

Dalam penelitian ini analisis klasifikasi akan dilakukan dengan metode *Support Vector Machine*, *Naive Bayes*, *Gradient Boosting* dan *Neural Network* sebagai *Early Warning System*. Kedua metode klasifikasi tersebut akan dievaluasi menggunakan metode *Cross Validation*. Langkah-langkah analisis dalam penelitian ini adalah sebagai berikut:

1. Membuat analisa deskriptif terhadap data.
2. Melakukan analisis cluster menggunakan metode *K-Means Clustering*, dengan tahapan sebagai berikut:
 - a. Melakukan stratifikasi pada data.
 - b. Membagi data menjadi 5 bagian yang sama.
 - c. Mengambil sampel satu bagian data sebagai data testing dan menggunakan 4 bagian data lainnya sebagai data training.
3. Memberikan label/flag sesuai cluster yang terbentuk
4. Melakukan analisis menggunakan metode analisis *Support Vector Machine*
5. Melakukan analisis menggunakan metode *Naive Bayes*
6. Melakukan analisis menggunakan metode *Gradient Boosting*

7. Melakukan analisis menggunakan metode *Neural Network*
8. Membandingkan nilai AUC dari 4 metode klasifikasi yang digunakan
9. Memilih metode yang terbaik
10. Menyusun kesimpulan dan saran

4. HASIL PENELITIAN DAN PEMBAHASAN

4.1 Analisis Statistika Deskriptif

Analisa statistika deskriptif bertujuan untuk mengetahui karakteristik dari data. Berikut ini adalah hasil statistika deskriptif dari seluruh variabel yang digunakan:

Tabel 4.1. Statistika Deskriptif Variabel X

	x1	x2	x3	x4	x5	x6	x7	x8	x9	x10	x11	x12
Avr	0.0068	0.0001	0.3433	1.5344	0.0091	0.0161	0.1795	0.5677	0.0678	0.0016	1.3184	0.6246
Me d	-	-	-	0.0134	-	-	0.1314	0.2751	0.0818	0.0006	0.2814	0.6391
Var	0.0005	0.0000	6.7496	553.6310	0.0010	0.0050	0.0383	0.6013	0.0025	0.0000	291.2845	0.0298
Min	-	-	6.3018	-301.7205	-	-	0.0013	0.0046	0.1113	0.0147	-205.1585	0.0461
Max	0.1671	0.0047	22.3693	48.3033	0.2724	0.6108	1.4742	4.2797	0.2477	0.0245	20.1521	0.9573

Berdasarkan tabel diatas, dapat disimpulkan bahwa:

- Variabel X1 (*Dependence Degree of Debt*) memiliki nilai pemusatan data yaitu rata-rata sebesar 0,0068 dan median sebesar 0,0000 dengan nilai maksimal 0,1671 dan minimal 0,0000. Nilai median dan nilai minimal memiliki nilai yang sama sebesar 0,0000, artinya lebih dari 50% data sampel yang digunakan memiliki nilai 0,0000 atau tidak memiliki *Current New Debt*. Dapat disimpulkan bahwa mayoritas data sampel termasuk kedalam kategori *mild warning*.

- Variabel X2 (*Debt Ratio*) memiliki nilai pemusatan data yaitu rata-rata sebesar 0,0001 dan median sebesar 0,0000

dengan nilai maksimal 0,0047 dan minimal 0,0000. Rata-rata dari data sampel yang digunakan hanya memiliki *debt ratio* sebesar 0,10% atau termasuk kedalam kategori *mild warning*.

- Variabel X3 (*New Debt Ratio*) memiliki nilai rata-rata sebesar 0,3433 dan median sebesar 0,0000 dengan nilai maksimal 22,3693 dan minimal 0,0000. Hal tersebut mengindikasikan bahwa mayoritas data sampel yang digunakan tidak memiliki *New Debt Ratio*, namun terdapat beberapa data sampel yang memiliki *New Debt Ratio* yang cukup besar sehingga mengakibatkan nilai rata-rata dan median berbeda cukup signifikan. Berdasarkan hal tersebut, mayoritas data sampel yang digunakan masuk kedalam kategori *mild warning*, namun terdapat beberapa data sampel yang memiliki nilai ekstrem tinggi yang berarti terdapat beberapa data sampel yang masuk kategori *severe warning*.

- Variabel X4 (*Rasio of GDP Growth to Debt Growth*) memiliki nilai rata-rata sebesar -1,5344 dan median sebesar 0,0134 dengan nilai maksimal 48,3033 dan minimal -301,7205 serta nilai varian sebesar 553,6310. Hal ini mengindikasikan bahwa dari data sampel yang digunakan, terdapat data yang memiliki negatif cukup besar sehingga mengakibatkan nilai rata-rata negatif sedangkan median memiliki nilai positif. Berdasarkan nilai rata-rata dan median, sebagian besar data sampel yang digunakan masuk ke dalam kategori *severe warning*.

- Variabel X5 (*Cost of Debt*) memiliki nilai rata-rata sebesar 0,0091 dan median

sebesar 0,0000 dengan nilai maksimal 0,2724 dan minimal 0,0000 serta nilai varian sebesar 0,0010. Berdasarkan nilai rata-rata dan median serta varian, dapat disimpulkan bahwa mayoritas data sampel yang digunakan memiliki nilai dibawah 5,93% sehingga termasuk kedalam kategori *mild warning*.

- Variabel X6 (*Debt Servicing Ratio*) memiliki nilai rata-rata sebesar 0,0161 dan median sebesar 0,0000 dengan nilai maksimal 0,6108 dan minimal 0,0000 serta nilai varian sebesar 0,0050. Nilai rata-rata dan median berada dibawah angka 15,00% sehingga mayoritas data sampel yang digunakan masuk kedalam kategori *mild warning*.

- Variabel X7 (*Debt Burden Ratio*) memiliki nilai rata-rata sebesar 0,1795 dan median sebesar 0,1314 dengan nilai maksimal 1,4742 dan minimal 0,0013 serta nilai varian sebesar 0,0383. Nilai rata-rata dan median berada dibawah angka 20,00% sehingga mayoritas data sampel yang digunakan masuk kedalam kategori *mild warning*.

- Variabel X8 (*Aset-liability Ratio*) memiliki nilai rata-rata sebesar 0,5677 dan median sebesar 0,2751 dengan nilai maksimal 4,2797 dan minimal 0,0046 serta nilai varian sebesar 0,6013. Nilai rata-rata dan median berada dibawah angka 30,00% sehingga mayoritas data sampel yang digunakan masuk kedalam kategori *mild warning*.

- Variabel X9 (*GDP Growth*) memiliki nilai rata-rata sebesar 0,0678 dan median sebesar 0,0818 dengan nilai maksimal 0,2477 dan minimal -0,1113

serta nilai varian sebesar 0,0025. Nilai rata-rata berada diantara 0,00% sampai dengan 7,00% sehingga dapat disimpulkan bahwa mayoritas data sampel yang digunakan berada pada kategori moderate warning.

- Variabel X10 (Deficit Ratio) memiliki nilai rata-rata sebesar 0,0016 dan median sebesar 0,0006 dengan nilai maksimal 0,0245 dan minimal -0,0147 serta nilai varian sebesar 0,0000. Nilai rata-rata berada diantara 0,00% sampai 1,00 persen sehingga dapat disimpulkan bahwa mayoritas data sampel yang digunakan berada pada kategori mild warning.

- Variabel X11 (Change of Fiscal Revenue and Expenditure) memiliki nilai rata-rata sebesar -1,3184 dan median sebesar 0,2814 dengan nilai maksimal 20,1521 dan minimal -205,1585 serta nilai varian sebesar 291,2845. Nilai rata-rata berada diatas 100% (mild warning) namun median berada dibawah nilai 50% (severe warning).

- V X12 Tingkat ketergantungan fiskal memiliki nilai rata-rata sebesar 0,6246 dan median sebesar 0,6391 dengan nilai maksimal 0,9573 dan minimal 0,0461 serta nilai varian sebesar 0,0298. Berdasarkan hal tersebut, tingkat ketergantungan Provinsi akan TKDD dapat dikatakan masih cukup besar. Rata-rata dari 34 Provinsi selama tahun 2016 sampai dengan 2020 adalah sebesar 62,46% dengan varian sebesar 2,98%.

4.2 K-Means Cluster Analysis

Analisis K-means cluster adalah unsupervised learning yang digunakan untuk mengelompokkan data berdasarkan karakteristik dari variabel yang digunakan. Seluruh variabel yang digunakan dalam penelitian ini akan dikelompokkan sesuai dengan karakteristiknya masing-masing. Jumlah cluster optimal dapat dilihat berdasarkan silhoutte score yang paling tinggi. Dari hasil analisis yang dilakukan, diperoleh silhoutte score sebagai berikut:

Tabel 4.2. *Silhoutte Score K-Means Cluster*

Jumlah Cluster	Silhoutte Score
2	0,584
3	0,546
4	0,553
5	0,272
6	0,156

Berdasarkan tabel diatas, dapat disimpulkan bahwa jumlah cluster optimal yang diperoleh adalah sejumlah 2 cluster dengan nilai silhoutte score sebesar 0,584. Setiap Cluster yang terbentuk memiliki karakteristik sebagai berikut:

Tabel 4.3. *Karakteristik Masing-Masing Cluster*

Cluster	Karakteristik
Cluster1	Pemerintah Provinsi dengan <i>Debt Balance Current Year</i> yang relatif rendah, Debt Principal Repayment yang cukup rendah
Cluster2	Pemerintah Provinsi dengan <i>Debt Balance Current Year</i> yang tinggi, Debt Principal Repayment yang cukup tinggi

Dari 170 data yang digunakan, 161 diantaranya masuk kedalam Cluster1 dan 9 sisanya masuk kedalam Cluster2.

Berdasarkan hal tersebut, dapat disimpulkan bahwa hanya terdapat 9 data yang masuk kedalam cluster 2 (*Severe Risk*) sedangkan 161 lainnya masuk kedalam cluster 1 (*Mild Risk*). Hasil dari analisis *cluster k-means* digunakan untuk flagging data sampel yang digunakan kedalam 2 kategori, untuk selanjutnya digunakan sebagai variabel respon (y) dalam membentuk model klasifikasi.

4.3 Analisis Klasifikasi

Analisis klasifikasi bertujuan untuk mengklasifikasikan risiko pembayaran kembali pinjaman oleh Pemerintah Provinsi.s. Variabel respon (y) yang digunakan dalam penelitian ini adalah hasil dari analisis *cluster* yang dilakukan sebelumnya. Terdapat 2 kategori variabel respon, yaitu *Mild Risk* dan *Severe Risk*.

4.3.1 Klasifikasi Menggunakan *Naive Bayes Classifier*

Berdasarkan hasil analisis menggunakan *naive bayes classifier* dengan menggunakan metode evaluasi *cross-validation* menggunakan 5 *folds*, diperoleh *confussion matrix* sebagai berikut:

Tabel 4.4. *Confussion Matrix Naive Bayes Classifier*

		Prediksi	
		C1	C2
Aktual	C1	135	26
	C2	0	9

Berdasarkan *confussion matrix* diatas, diperoleh hasil prediksi C1 yang sesuai dengan data sebenarnya (*True Positive*) adalah sejumlah 135, hasil prediksi C2

yang sesuai dengan data sebenarnya (*True Negative*) adalah sejumlah 9, hasil prediksi C2 yang masuk kategori aktual C1 (*False Positive*) adalah sejumlah 26 dan hasil prediksi C1 yang masuk kategori C2 (*False Negative*) adalah sejumlah 0. Tahap selanjutnya adalah melakukan perhitungan evaluasi kebaikan sebagai berikut:

Tabel 4.5. *Ukuran Kebaikan Model Naive Bayes Classifier*

AUC	F1 Score	Presicion	Recall
0,955	0,886	0,961	0,847

Dari hasil evaluasi model menggunakan *cross-validation* dengan 5 *folds*, diperoleh nilai AUC sebesar 95,5% dan F1 *score* sebesar 88,6%. Nilai tersebut menjadikan model klasifikasi *Naive Bayes Classifier* tergolong sangat baik digunakan untuk memprediksi risiko pembayaran pinjaman oleh Pemerintah Provinsi di Indonesia.

4.3.2 Klasifikasi Menggunakan *Gradient Boosting Machine*

Berdasarkan hasil analisis menggunakan *Gradient Boosting Machine* dengan menggunakan metode evaluasi *cross-validation* menggunakan 5 *folds*, diperoleh *confussion matrix* sebagai berikut:

Tabel 4.6. *Confussion Matrix Gradient Boosting Machine*

		Prediksi	
		C1	C2
Aktual	C1	161	0
	C2	2	7

Berdasarkan *confussion matrix* diatas, diperoleh hasil prediksi C1 yang sesuai dengan data sebenarnya (*True Positive*) adalah sejumlah 161, hasil prediksi C2

yang sesuai dengan data sebenarnya (*True Negative*) adalah sejumlah 7, hasil prediksi C2 yang masuk kategori aktual C1 (*False Positive*) adalah sejumlah 0 dan hasil prediksi C1 yang masuk kategori C2 (*False Negative*) adalah sejumlah 2. Tahap selanjutnya adalah melakukan perhitungan evaluasi kebaikan sebagai berikut:

Tabel 4.7. Ukuran Kebaikan Model Gradient Boosting Machine

AUC	F1 Score	Presicion	Recall
0,884	0,988	0,988	0,988

Dari hasil evaluasi model menggunakan *cross-validation* dengan 5 folds, diperoleh nilai AUC sebesar 88,4% dan F1 score sebesar 98,6%. Nilai tersebut menjadikan model klasifikasi *Gradient Boosting Machine* tergolong sangat baik digunakan untuk memprediksi risiko pembayaran pinjaman oleh Pemerintah Provinsi di Indonesia.

4.3.3 Klasifikasi Menggunakan Support Vector Machine

Berdasarkan hasil analisis menggunakan Support Vector Machine dengan menggunakan metode evaluasi *cross-validation* menggunakan 5 folds, diperoleh *confussion matrix* sebagai berikut:

Tabel 4.8. Confussion Matrix Support Vector Machine

		Prediksi	
		C1	C2
Aktual	C1	160	1
	C2	7	2

Berdasarkan *confussion matrix* diatas, diperoleh hasil prediksi C1 yang sesuai dengan data sebenarnya (*True Positive*)

adalah sejumlah 160, hasil prediksi C2 yang sesuai dengan data sebenarnya (*True Negative*) adalah sejumlah 2, hasil prediksi C2 yang masuk kategori aktual C1 (*False Positive*) adalah sejumlah 1 dan hasil prediksi C1 yang masuk kategori C2 (*False Negative*) adalah sejumlah 7. Tahap selanjutnya adalah melakukan perhitungan evaluasi kebaikan sebagai berikut:

Tabel 4.9. Ukuran Kebaikan Model Support Vector Machine

AUC	F1 Score	Presicion	Recall
0,997	0,942	0,943	0,953

Dari hasil evaluasi model menggunakan *cross-validation* dengan 5 folds, diperoleh nilai AUC sebesar 99,7% dan F1 score sebesar 94,2%. Nilai tersebut menjadikan model klasifikasi *Support Vector Machine* tergolong sangat baik digunakan untuk memprediksi risiko pembayaran pinjaman oleh Pemerintah Provinsi di Indonesia.

4.3.4 Klasifikasi Menggunakan Neural Network

Berdasarkan hasil analisis menggunakan Neural Network dengan menggunakan metode evaluasi *cross-validation* menggunakan 5 folds, diperoleh *confussion matrix* sebagai berikut:

Tabel 4.10. Confussion Matrix Neural Network

		Prediksi	
		C1	C2
Aktual	C1	160	1
	C2	1	8

Berdasarkan *confussion matrix* diatas, diperoleh hasil prediksi C1 yang sesuai dengan data sebenarnya (*True Positive*) adalah sejumlah 160, hasil prediksi C2

yang sesuai dengan data sebenarnya (*True Negative*) adalah sejumlah 8, hasil prediksi C2 yang masuk kategori aktual C1 (*False Positive*) adalah sejumlah 1 dan hasil prediksi C1 yang masuk kategori C2 (*False Negative*) adalah sejumlah 1. Tahap selanjutnya adalah melakukan perhitungan evaluasi kebaikan sebagai berikut

Tabel 4.11. Ukuran Kebaikan Model Neural Network

AUC	F1 Score	Presicion	Recall
0,997	0,988	0,988	0,988

Dari hasil evaluasi model menggunakan *cross-validation* dengan 5 *folds*, diperoleh nilai AUC sebesar 99,7% dan F1 score sebesar 98,8%. Nilai tersebut menjadikan model klasifikasi *Neural Network* tergolong sangat baik digunakan untuk memprediksi risiko pembayaran pinjaman oleh Pemerintah Provinsi di Indonesia.

4.4 Perbandingan Ukuran Kebaikan Model Prediksi

Setiap model klasifikasi memiliki keunggulannya masing-masing, sehingga perlu membandingkan model terbaik untuk mengklasifikasikan risiko individu kemampuan membayar kembali pinjaman Pemerintah Provinsi. Pemilihan model terbaik didasarkan pada nilai AUC dan F1 Score tertinggi. Berikut disajikan ukuran kebaikan model untuk setiap metode:

Tabel 4.12. Perbanding Seluruh Metode Klasifikasi Yang Digunakan

Metode	AUC	F1 Score
<i>Naive Bayes</i>	0,955	0,886
<i>Gradient Boosting Machine</i>	0,884	0,988
<i>Support Vector Machine</i>	0,997	0,942

Neural Network	0,997	0,988
-----------------------	--------------	--------------

Berdasarkan tabel diatas, dapat dilihat bahwa nilai AUC tertinggi dihasilkan pada oleh model *Neural Network* yaitu sebesar 0,997. Artinya model *Neural Network* dengan metode evaluasi *cross validation 5 folds* dapat memprediksi kategori risiko pembayaran kembali pinjaman Pemerintah Provinsi di Indonesia sebesar 99,70%. Begitu juga nilai F1 Score tertinggi dihasilkan oleh model *Neural Network* yaitu sebesar 0,988.

5. KESIMPULAN DAN SARAN

5.1 KESIMPULAN

- Analisis *cluster* dengan menggunakan metode k-means clustering menghasilkan cluster optimum sebanyak 2 cluster dengan *silhoutte score* sebesar 0,584.
- Klasifikasi menggunakan metode *Naive Bayes Classifier* menghasilkan nilai AUC sebesar 0,955 dan F1 Score sebesar 0,866.
- Klasifikasi menggunakan metode *Gradient Boosting Machine* menghasilkan nilai AUC sebesar 0,884 dan F1 Score sebesar 0,988.
- Klasifikasi menggunakan metode *Support Vector Machine* menghasilkan nilai AUC sebesar 0,997 dan F1 Score sebesar 0,942.
- Klasifikasi menggunakan metode *Neural Network* menghasilkan nilai AUC sebesar 0,997 dan F1 Score sebesar 0,988.
- Metode klasifikasi terbaik untuk memprediksi risiko pembayaran kembali pinjaman Pemerintah Provinsi adalah *Neural Network*

dengan metode evaluasi *Cross Validation*.

5.2 SARAN

Pada tahap analisis klasifikasi, variabel respon (y) memiliki kategori yang tidak seimbang (*imbalance*). Sehingga pada penelitian selanjutnya diharapkan menggunakan metode yang mampu mengakomodir permasalahan *imbalance* data.

6. IMPLIKASI DAN KETERBATASAN

Penelitian ini menghasilkan model klasifikasi yang mampu membedakan kategori risiko pembayaran kembali pinjaman pemerintah daerah. Sehingga penelitian ini diharapkan dapat menjadi dasar penentuan *individual risk* masing-masing Pemerintah Provinsi sebelum menerima pinjaman. Dengan demikian, risiko gagal bayar pinjaman oleh Pemerintah Provinsi dapat dihindari sejak dini.

Namun terdapat keterbatasan dalam penelitian ini yaitu dalam penelitian ini hanya menggunakan *individual risk* pada masing-masing Pemerintah Provinsi. Dimana terdapat *contagion risk* yang juga berpotensi mempengaruhi risiko gagal pinjaman oleh Pemerintah Provinsi.

7. REFERENSI

- Antulov-Fantulin N & Lagravinese R, Resce G. (2021). *Predicting bankruptcy of local government: A machine learning approach*. Journal of Economic Behavior & Organization.
- Bekkar, Mohamed., & Djemaa, H.K., Alitouche, T.A. (2013). *Evaluation Measures for Models Assesment Over Imbalanced Data Sets*. Journal of Information Engginering and Application, Vol. 3, NO.10.
- Erke, A. R. V. & Pattynama, P. M. T., (1998). *Receiver operating characteristic (ROC) analysis: Basic principlesn and application in radiologi*. European Journal of Radiology.
- Fuertes AM, Kalotychou (2006). *Early warning systems for sovereign debt crises: The role of heterogeneity*. *Computational Statistics & Data Analysis*. 51(2).
- Hermansyah, Hukum Perbankan Nasional Indonesia, (2005), Jakarta: Kencana.
- International Conference on Advanced Computer Control, Shenyang, China. 2010; <https://doi.org/10.1152/ajprenal.2001.281.3.F493> PMID: 11502598.
- Kamra, (2013), *K. Debt crisis determinants: Early warning indicators for emerging markets*. Doctoral Dissertation, Tufts University, Boston, USA.
- Shi SA, Li BS, Xia L. (2010). *Studying on fiscal risk early-warning based on BP neural network*.
- Tao KY. (2015). *Assessing local government debt risks in China: A case study of local government finansial vehicles*. *China & World Economy*. 23(5).
- Xing Li, Xiangyu Ge, Cong Chen, (2020), *Several explorations on how to construct an early warning system for*

local government debt risk in China,
China: PLOS ONE.

Zweig, M. H., & Campbell, G. (1993).
Receiver-operating characteristic
(ROC) plots: a fundamental
evaluation tool in clinical medicine.
Clinical chemistry, 39(4).